

Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Физтех-школа прикладной математики и информатики
Кафедра интеллектуальных систем

Веприков Андрей Сергеевич

**ЗАДАЧА ОПТИМАЛЬНОГО УПРАВЛЕНИЯ В
СИСТЕМАХ
ИСКУССТВЕННОГО ИНТЕЛЛЕКТА С ОБРАТНОЙ
СВЯЗЬЮ**

03.04.01 «Прикладные математика и физика»

Выпускная квалификационная работа магистра

Научный руководитель:
Хританков Антон Сергеевич,
к. ф.-м. н.

Москва, 2026

Аннотация

В данной работе рассматривается задача оптимального управления в системе машинного обучения (МО) со скрытой петлей обратной связи. Под обратной связью понимается ситуация, когда предсказания модели на предыдущих шагах меняют обучающую выборку на текущем шаге. В работах автора [1, 2] такие системы изучались как дискретные динамические системы, найдены условия существования и сходимости их предельного множества. В настоящей работе в систему вводится управление u_t , действующее на алгоритм обучения, а задача формулируется как максимизация суммарной награды при условии, что петля обратной связи не разрушается и система не вырождается.

Постановка строится как расширение PoMDP. Оператор эволюции делится на две части, отвечающие за обучение модели и за реакцию среды, а допустимость управления задается определенным условием. Эта постановка применяется к двум сюжетам. В первом сюжете рассматривается задача прогнозирования цен на жилье, в которой наблюдается деградация системы. Во втором сюжете рассматривается метод Generative Replay в задаче непрерывного обучения. Для каждого сюжета конкретизируются оператор обучения, условие существования петли и функция награды.

Получены следующие теоретические результаты. Доказаны достаточные условия допустимости управления через липшицевость функции потерь и через устойчивость алгоритма обучения к замене одного примера в обучающей выборке. Получена верхняя оценка средней ошибки модели на всех изученных задачах для произвольного расписания управления. Решена обратная задача восстановления управления по заданным целевым весам задач в финальной модели. В квадратичном приближении функции потерь выведены замкнутые формулы шага Generative Replay и спектральная оценка финальной ошибки. Отдельно получено разложение средней ошибки на компоненты смещения и дисперсии в случае одинаковых гессианов задач и независимых оптимумов. Условия сходимости в среднем квадратичном оказываются эквивалентны классическим условиям Роббинса-Монро на расписание.

Все теоретические утверждения проверяются экспериментально. На синтетических задачах подтверждаются предсказания спектральной теории. На линейной рекурсии с независимыми случайными оптимумами эмпирическая ошибка модели совпадает с предсказанием теории в пределах 0,3% при $K = 3000$

независимых реализациях. На реальном датасете NIH ChestX-Ray расписание $u_t = \alpha/(t + 1)$ с $\alpha = 1,5$ для последовательной классификации пяти заболеваний поверх класса «норма» уступает совместному многоклассовому обучению на 5,5 процентного пункта по средней метрике AUC.

Содержание

Введение	6
1 Связанные работы	10
1.1 Петли обратной связи и деградация систем МО	10
1.2 Доверие, безопасность и социально ответственный ИИ	11
1.3 Оптимальное управление и стохастическая аппроксимация	11
1.4 Replay и Generative Replay в непрерывном обучении	12
1.5 ChestX-Ray и MobileNetV2	13
2 Постановка задачи	14
2.1 Состояние и эволюция	14
2.2 Награда и условие допустимости	14
2.3 Оптимизационная задача	15
2.4 Сравнение с PoMDP	15
2.5 Жадный алгоритм	16
2.6 Непустота множества допустимых управлений	16
3 Основные результаты	18
3.1 Деградация системы при прогнозировании цен	18
3.1.1 Конкретизация общей постановки	18
3.1.2 Жадная стратегия и эффект деградации	19
3.1.3 Аккуратное управление через зависимость от наблюдаемой выборки	20
3.1.4 Обсуждение	21
3.2 Generative Replay в задаче непрерывного обучения	21
3.2.1 Конкретизация общей постановки	22
3.2.2 Достаточные условия допустимости управления	23
3.2.3 Верхняя оценка средней ошибки и обратная задача	25
3.2.4 Спектральная теория ошибки в квадратичном приближении	29
3.2.5 Bias–variance анализ и связь с классической теорией	32
3.2.6 Жадный порядок задач и адаптивное расписание	34
3.2.7 Обсуждение	36

4 Эксперименты	37
4.1 Деградация системы при прогнозировании цен	37
4.2 Generative Replay в задаче непрерывного обучения	39
4.2.1 Общий протокол обучения	40
4.2.2 Регрессия параболы линейной моделью	41
4.2.3 Ортогональные носители гессианов	43
4.2.4 Жадный выбор порядка задач	44
4.2.5 Bias-variance разложение	45
4.2.6 ChestX-Ray	47
Заключение	52
Приложение А. Непустота множества допустимых управлений	60
Приложение Б. Достаточные условия допустимости управления	61
Приложение В. Верхняя оценка средней ошибки и обратная задача	64
Приложение Г. Спектральная теория ошибки в квадратичном при- ближении	69
Приложение Д. Bias-variance анализ и связь с классической теори- ей	74
Приложение Е. Детали экспериментов	78

Введение

В работе изучается задача оптимального управления в системе машинного обучения с обратной связью [3, 4]. Под обратной связью понимается ситуация, когда состояние внешней среды и обучающая выборка алгоритма частично формируются собственными предсказаниями модели на предыдущих шагах. Такая ситуация типична для систем с длинным жизненным циклом, например, для рекомендательных сервисов [5, 6], систем предиктивного полицейского контроля [7], прогнозирования цен [8], поддержки принятия медицинских решений [9, 10] и фильтр-пузырей в социальных сетях [11, 12, 13].

В работах автора [1, 2, 14] процесс многократного обучения был описан как дискретная динамическая система $f_{t+1}(x) = \mathbf{D}_t(f_t)(x)$ в пространстве плотностей данных. Были доказаны условия, при которых $\mathbf{D}_t$ является преобразованием на множестве плотностей, исследованы свойства предельного множества и его поведение при преобразованиях пространства признаков. Этого описания достаточно, чтобы зафиксировать факт наличия петли обратной связи и оценить ее влияние на распределение данных. Однако вопрос о том, как менять алгоритм обучения, чтобы петля не вызывала нежелательных эффектов, в этих работах не ставился. Именно эта задача решается в настоящей работе.

Содержательная мотивация состоит в следующем. Рассмотрим систему прогнозирования цен на жилье [3, 8]. Предсказания модели влияют на решения покупателей, а решения покупателей формируют активную выборку для последующих обновлений модели. Возникает петля обратной связи. Управление в такой системе позволяет менять рекомендуемую цену и через петлю влиять на распределение данных. Естественно поставить задачу так: выбирать управление, при котором средняя цена сделки растет. Однако управление не может быть произвольным. Если рекомендации становятся слишком агрессивными, покупатели уходят, петля разрушается, а вместе с ней и сама система. Поэтому управление должно сохранять петлю обратной связи. Именно такой задачей оптимального управления с условием на сохранение петли и занимается настоящая работа.

Формальная постановка строится как расширение PoMDP. К стандартной пятерке $(\mathcal{S}, \mathcal{U}, \mathbf{D}, r, \gamma)$ добавляются два нестандартных элемента. Во-первых, оператор эволюции $\mathbf{D}$ разделяется на оператор обучения модели $\mathbf{H}_t$ и оператор реакции среды $\mathbf{P}_t$. Это разделение естественно для постановки, потому что исследователь управляет только моделью, а среду наблюдает косвенно через

ограниченную выборку. Во-вторых, вводится условие $g(f_t, h_{t+1}) \leq 0$, в которое заложена сама петля обратной связи и условия ее корректной работы. Управление $u_t \in \mathcal{U}$ выбирается из тех значений, при которых это условие выполнено. Оптимизационная задача имеет вид

$$\max_{u_1, \dots, u_\infty} \sum_{t=0}^{+\infty} \gamma^t r(f_t, h_{t+1})$$

при условиях

$$h_{t+1} = \mathbf{H}_t(f_t, h_t, u_t), \quad f_{t+1} = \mathbf{P}_t(f_t, h_{t+1}), \quad g(f_t, h_{t+1}) \leq 0.$$

Дополнительная сложность связана с тем, что плотности f_t исследователю не доступны. На каждом шаге наблюдается только ограниченная выборка из f_t .

Введенная постановка применяется к двум сюжетам. В первом сюжете изучается эффект деградации системы в задаче прогнозирования цен. Оператор $\mathbf{P}_t$ моделирует решения покупателей. С вероятностью, зависящей от рекомендации модели, покупатель либо подтверждает сделку, либо уходит из системы. Функция g контролирует объем активной выборки. На этом сюжете показано, что без явной зависимости g от текущего распределения данных жадное управление поднимает локальные метрики и одновременно ведет к оттоку пользователей. В пределе активная выборка пустеет и система перестает работать. Второй сюжет посвящен методу Generative Replay [15] в задаче непрерывного обучения. Модель учится последовательно на потоке задач. Чтобы предыдущие задачи не забывались, на каждом шаге обучающая выборка собирается из двух источников. Часть примеров приходит из новой задачи. Остальные примеры синтезируются для уже изученных задач и помечаются ответами текущей модели. Управление $u_t \in [0, 1]$ задает долю новых данных в выборке. Условие g требует, чтобы внутренняя оптимизация на каждом шаге достигала заданного уровня точности. В настоящей работе впервые предложена формальная запись метода Generative Replay в виде задачи оптимального управления.

Общая характеристика работы

Применимость. В реальных системах модели машинного обучения после развертывания продолжают регулярно дообучаться на свежих данных. Поток

данных в таких системах нестационарен: появляются новые классы, редкие события, меняются предпочтения пользователей. Этот режим эксплуатации изучается в рамках непрерывного обучения [16, 17]. Регулярное обновление развернутой модели на нестационарных данных порождает скрытые петли обратной связи и формирует технический долг [18]. Постановка настоящей работы покрывает этот режим: операторы $\mathbf{H}_t$ и $\mathbf{P}_t$ моделируют один цикл обновления модели и реакции среды, условие g фиксирует требования к долгосрочному поведению системы, а управление u_t становится переменной оптимизации, по которой подбирается режим дообучения.

Положения, выносимые на защиту. На защиту выносятся следующие результаты.

1. Единая постановка задачи оптимального управления в системе машинного обучения со скрытой петлей обратной связи. Введена пятерка $(\mathcal{S}, \mathcal{U}, \mathbf{D}, r, \gamma)$ с разделением оператора эволюции на оператор обучения $\mathbf{H}_t$ и оператор реакции среды $\mathbf{P}_t$, а также условие допустимости $g(f_t, h_{t+1}) \leq 0$, в которое заложены требования к сохранению петли и к невырождению системы (Раздел 2).
2. Эффект деградации системы как частный случай общей постановки. На задаче прогнозирования цен показано, что без явной зависимости условия g от наблюдаемой выборки жадная стратегия выводит систему в нерабочий режим. Введение более аккуратного условия восстанавливает работоспособность без потери локальной метрики качества (подраздел 3.1).
3. Метод Generative Replay в задаче непрерывного обучения как частный случай общей постановки. Управление $u_t \in [0, 1]$ интерпретируется как доля новых данных в обучающей выборке (подраздел 3.2).
4. Достаточные условия допустимости управления через липшицевость функции потерь и через устойчивость алгоритма обучения к замене одного примера в обучающей выборке (Теоремы 1 и 2).
5. Верхняя оценка средней ошибки модели на всех изученных задачах для произвольного расписания управления (Теорема 3) и обратная задача

восстановления расписания по заданным целевым весам задач с явной формулой $u_t = \alpha_{t+1}/S_{t+1}$ (Предложение 2).

6. Спектральная теория ошибки Generative Replay. Замкнутая форма шага через гессианы задач, основная спектральная оценка средней ошибки (Теорема 4) и безусловная оценка (Теорема 5).
7. Разложение средней ошибки на компоненты смещения и дисперсии при одинаковых гессианах задач и независимых случайных оптимумах (Теорема 6). Условия сходимости в среднем квадратичном (Теорема 7) совпадают с классическими условиями Роббинса-Монро [19].
8. Экспериментальная проверка теоретических результатов на синтетических задачах и на реальном датасете медицинских изображений NIH ChestX-Ray (Раздел 4).

Личный вклад автора. Все теоретические результаты, изложенные в работе, получены лично автором. Реализация экспериментов и обработка результатов также выполнены автором.

Структура работы. В Разделе 1 собран обзор связанных работ по петлям обратной связи, теории управления и методу Generative Replay. В Разделе 2 формализуется задача оптимального управления и описываются ее две конкретизации. В Разделе 3 излагаются основные теоретические результаты: эффект деградации системы при прогнозировании цен (подраздел 3.1) и теория Generative Replay (подраздел 3.2). В Разделе 4 приводится экспериментальная проверка на синтетических задачах и на реальном датасете.

1. Связанные работы

В обзоре собраны три тематические линии, на пересечении которых лежит задача данной работы. Это петли обратной связи в системах МО, теория оптимального управления применительно к задачам обучения, и метод Generative Replay в непрерывном обучении. В литературе нет работы, в которой эти три линии объединены в одной постановке.

1.1. Петли обратной связи и деградация систем МО

Идея о том, что система машинного обучения с длинным жизненным циклом сама влияет на свою обучающую выборку, появлялась в нескольких прикладных контекстах. В работе [3] даны достаточные условия появления скрытой петли обратной связи в рекомендательных системах. Та же модель проверена на симуляции в [8]. В статье [4] показано, что положительная обратная связь приводит к концепт-дрифту с измеримой скоростью.

В работе [6] рекомендательные системы рассматриваются как динамическая модель, а также описаны вырожденные петли, при которых система навсегда уходит в одну категорию контента. В [7] задокументирован аналогичный эффект для предиктивного полицейского контроля. Алгоритм направляет патрулирование в районы с большим числом зафиксированных инцидентов, что увеличивает регистрируемые инциденты именно в этих районах. В пределе обучающая выборка теряет связь с реальным распределением правонарушений. Аналогичный анализ для систем поддержки принятия медицинских решений приведен в [9]. В работе [10] показано, что регулярное обновление развернутой модели может усиливать ошибки, накопленные в предыдущих версиях.

В статье [5] рассматривается задача разложения наблюдаемой обратной связи в рекомендательной системе на истинное предпочтение пользователя и эффект самой рекомендации. В [20] формализован data feedback loop в задаче обучения языковых моделей и доказана амплификация начальных смещений датасета. В близкой по духу работе [21] рассмотрены эффекты несправедливости в МО, многие из которых порождаются именно скрытыми петлями обратной связи. Социокультурный аспект явления обсуждается в работах о фильтр-пузырях [11, 12, 13].

Отдельная линия представлена собственными работами автора [1, 2, 14]. В [1] процесс многократного обучения описан как дискретная динамическая

система $f_{t+1}(x) = \mathbf{D}_t(f_t)(x)$ в пространстве плотностей данных. Доказаны достаточные условия, при которых $\mathbf{D}_t$ является преобразованием, найдены условия сходимости и условие автономности. В [2] исследуется, как меняется предельное множество системы при преобразованиях пространства признаков. Этот результат обобщает анализ [4, 8] на более широкий класс моделей. Конференционная версия результатов [14] была доложена на ММРО-2023. В этих работах изучалась динамика плотностей данных как таковая. В настоящей работе дополнительно вводится управление u_t , оператор $\mathbf{D}_t$ разделяется на $\mathbf{H}_t$ и $\mathbf{P}_t$, и ставится задача выбора u_t , при котором система остается в работоспособном режиме.

Перечисленные работы описывают наблюдаемые эффекты, но не дают конструктивного механизма управления системой. В них либо измеряется наличие петли, либо оценивается ее влияние на качество предсказаний. Вопрос о том, как менять алгоритм обучения, чтобы система оставалась работоспособной, в явном виде не ставится. Этот пробел и заполняет настоящая работа.

1.2. Доверие, безопасность и социально ответственный ИИ

Параллельно с прикладными исследованиями петель обратной связи развивалась более общая дискуссия о свойствах систем ИИ, которые делают их пригодными для применения в социально значимых задачах. В заявлении [22] зафиксировано беспокойство сообщества о долгосрочных рисках. В работе [23] измеряется, как ошибки модели влияют на решения людей. В обзоре [24] систематизируется переход от принципов trustworthy AI к практическим рекомендациям. В [25] формулируются задачи социально ответственного ИИ. В работе [26] доверенные автономные системы рассматриваются с инженерной точки зрения.

Объединяющий тезис этих работ состоит в том, что система МО, оптимизирующая локальную метрику, может одновременно вести себя нежелательно по отношению к среде. В постановке настоящей работы этот тезис формализуется через условие $g(f_t, h_{t+1}) \leq 0$. Это условие отделяет разрешенные состояния системы от запрещенных. Управление выбирается не из множества всех возможных u_t , а только из тех значений, при которых условие выполнено.

1.3. Оптимальное управление и стохастическая аппроксимация

Базовый аппарат теории управления для систем с обратной связью изложен в монографиях [27, 28]. Дискретные динамические системы [29, 30] удобны

для описания процессов с временным шагом, согласованным с шагом обучения модели. На пересечении этих двух теорий лежит постановка настоящей работы. Оператор эволюции $\mathbf{D}_t$ из [1] соответствует автономной дискретной динамической системе. Добавленное управление u_t переводит ее в постановку оптимального управления.

Отдельный важный класс методов в управлении дискретными системами включает стохастическую аппроксимацию Роббинса-Монро [19]. Классический результат состоит в следующем. При условиях $\sum_t u_t = \infty$ и $\sum_t u_t^2 < \infty$ итерационная процедура сходится в среднем квадратичном к точке, в которой математическое ожидание шума равно нулю. В Разделе 3 показано, что обновление Generative Replay в режиме общего гессиана и независимых оптимумов задач сводится к скалярному экспоненциальному скользящему среднему и удовлетворяет в точности условиям Роббинса-Монро. Это делает $u_t = 1/(t + 1)$ не произвольным выбором, а специальной точкой расписания, в которой текущая модель является эмпирическим средним наблюдаемых оптимумов.

1.4. Replay и Generative Replay в непрерывном обучении

Идея воспроизведения примеров прошлых задач при обучении на новой задаче восходит к работе [31]. Простейший вариант метода Replay устроен так. На каждом шаге часть обучающей выборки прошлых задач хранится в буфере и подмешивается к данным текущей задачи. Модель видит и старые, и новые примеры одновременно, что препятствует катастрофическому забыванию. В работе [32] такой буфер совместно с дистилляцией от прежней модели используется для инкрементного обучения классификатора на потоке новых классов. В работе [33] буфер применяется иначе. На каждом шаге градиент обновления проецируется так, чтобы потери на хранимых примерах прошлых задач не возрастали.

Когда хранение реальных примеров невозможно или нежелательно, применяется метод Generative Replay [15]. Вместо буфера обучается генератор, который синтезирует примеры прошлых задач. Этот подход получил развитие в нескольких направлениях. В работе [34] предложен приоритизированный Generative Replay для обучения с подкреплением. Переходы из буфера семплируются по функции релевантности, например, по внутренней любознательности агента. Параметрический буфер на диффузионной модели обучается генерировать редкие, но важные переходы. В работе [35] предложен метод t-DGR.

Генератор обусловлен на номер временного шага траектории, что устраняет накопление ошибки авторегрессионной генерации в задачах принятия решений.

В перечисленных работах Generative Replay описан как инженерное решение задачи катастрофического забывания. Функция потерь представляется как линейная комбинация потерь на новой задаче и на синтетических примерах прошлых задач, а коэффициент линейной комбинации обсуждается из эвристических соображений или эмпирически. В настоящей работе совершен переход от инженерного описания к формализации Generative Replay как задачи оптимального управления. Доля новых данных $u_t \in [0, 1]$ становится переменной оптимизации, обучение модели на каждом шаге описывается оператором $\mathbf{H}_t$, а условие $g(f_t, h_{t+1}) \leq 0$ требует, чтобы внутренняя оптимизация достигла заданного уровня точности. В этой формализации удастся доказать допустимость нулевого управления, непустоту множества допустимых управлений на каждом шаге, а также получить верхнюю оценку средней ошибки модели для произвольного расписания.

1.5. ChestX-Ray и MobileNetV2

Для проверки теории на реальной задаче используется датасет NIH ChestX-Ray [36]. Он содержит более ста тысяч рентгеновских снимков грудной клетки с разметкой по 14 диагнозам и классом «норма». В качестве предсказательной модели берется MobileNetV2 [37]. Это легкая сверточная архитектура, ориентированная на ресурсограниченные устройства. Выбор объясняется двумя соображениями. В задаче непрерывного обучения дообучение модели на каждом блоке должно быть быстрым и стабильным, что плохо совместимо с тяжелыми архитектурами. Кроме того, MobileNetV2 дает качество, близкое к ResNet, на стандартных бенчмарках [37]. В Разделе 4 модель обучается последовательно на пяти патологиях поверх предварительно обученной на классе «норма».

Каждое из перечисленных направлений фиксирует отдельный эффект или частное решение и не дает единой формальной постановки. В следующем разделе три линии (петля обратной связи, выбор алгоритма обучения и поток задач) укладываются в пятерку $(\mathcal{S}, \mathcal{U}, \mathbf{D}, r, \gamma)$ с условием допустимости g .

2. Постановка задачи

В этом разделе формально вводится задача оптимального управления системой машинного обучения с обратной связью. Описывается состояние системы, оператор эволюции, функция награды, условие допустимости и сама оптимизационная задача.

2.1. Состояние и эволюция

Состояние системы на шаге t задается парой (f_t, h_t) . Функция f_t описывает плотность данных среды, функция h_t задает плотность весов модели θ . Сама модель обозначается через $m_\theta(\mathbf{x})$ и преобразует признаки $\mathbf{x}$ в предсказание. Множество всех возможных пар (f_t, h_t) обозначается через $\mathcal{S}$. Управление на шаге t обозначается через u_t и выбирается из заданного множества допустимых управлений $\mathcal{U}$. Управление действует только на алгоритм обучения и не действует на среду напрямую. Среда, в свою очередь, наблюдается косвенно. Исследователю доступна только ограниченная выборка из распределения f_t , но не само распределение.

Оператор эволюции системы разделяется на две части. Алгоритм обучения переводит распределение весов модели с шага t на шаг $t + 1$, и этот переход зависит от текущей выборки, текущей модели и управления:

$$h_{t+1} = \mathbf{H}_t(f_t, h_t, u_t), \quad \mathbf{H}_t \in \mathbf{H}. \quad (1)$$

Реакция среды переводит распределение данных и зависит от текущего распределения и от новой модели:

$$f_{t+1} = \mathbf{P}_t(f_t, h_{t+1}), \quad \mathbf{P}_t \in \mathbf{P}. \quad (2)$$

Класс операторов обучения $\mathbf{H}$ известен, так как алгоритм обучения исследователь выбирает сам. Класс операторов среды $\mathbf{P}$ исследователю не известен, и в большинстве прикладных задач его невозможно восстановить.

2.2. Награда и условие допустимости

Качество текущего состояния системы оценивается функцией награды $r(f_t, h_{t+1})$. Цель управления состоит в максимизации суммарной дисконтиро-

ванной награды по всему горизонту обучения. Коэффициент $\gamma \in (0, 1)$ задает дисконтирование и определяет, насколько далеко в будущее смотрит управление.

Кроме награды, в постановке используется функция $g(f_t, h_{t+1})$. В нее закладываются два требования. Во-первых, в системе должна сохраняться петля обратной связи, иначе постановка теряет смысл и изучаемое явление пропадает. Во-вторых, система не должна вырождаться. Например, число активных пользователей или объем активной выборки не должны падать к нулю. Управление u_t называется допустимым, если выполнено

$$g(f_t, h_{t+1}) \leq 0. \quad (3)$$

Поскольку f_t и h_{t+1} задают распределения, условие (3) понимается в стохастическом смысле. При заданном уровне риска $\delta \in (0, 1)$

$$\int_{\mathbf{x}} \int_{\boldsymbol{\theta}} \mathbf{1}\{g(\mathbf{x}, \boldsymbol{\theta}) \leq 0\} f_t(\mathbf{x}) h_{t+1}(\boldsymbol{\theta}) d\mathbf{x} d\boldsymbol{\theta} \geq 1 - \delta. \quad (4)$$

2.3. Оптимизационная задача

В принятых обозначениях задача оптимального управления имеет вид

$$\max_{u_1, u_2, \dots} \sum_{t=0}^{+\infty} \gamma^t r(f_t, h_{t+1}) \quad (5)$$

при ограничениях (1), (2), (3). В конечном горизонте T верхний предел в сумме заменяется на T , и постановка не меняется.

Доступны оператор обучения $\mathbf{H}_t$, который исследователь выбирает сам, множество $\mathcal{U}$, функция g и коэффициент γ . Доступна также ограниченная выборка $\hat{f}_t$, по которой можно оценивать состояние среды. Не доступны истинная плотность f_t и оператор реакции среды $\mathbf{P}_t$. Тем не менее, постановка (3)–(5) разрешима. Даже без знания $\mathbf{P}_t$ управление через петлю обратной связи в итоге сказывается и на распределении данных.

2.4. Сравнение с PoMDP

Постановка (3)–(5) расширяет частично наблюдаемый марковский процесс принятия решений. Стандартный PoMDP оперирует одним состоянием, одним действием, одним оператором перехода и одной наградой. В постановке на-

стоящей работы состояние раскладывается в пару (f_t, h_t) , оператор эволюции делится на две независимые части $\mathbf{H}_t$ и $\mathbf{P}_t$, и к постановке добавляется условие допустимости g . Первое отличие отражает то, что управление действует только на модель, а не на среду. Второе отличие отражает требования к поведению системы в процессе обучения.

2.5. Жадный алгоритм

В качестве простейшей стратегии управления рассматривается жадный алгоритм. На шаге t среди управлений $u_t \in \mathcal{U}$ оставляются те, для которых в текущем состоянии выполнено условие (4). Из оставшихся управлений выбирается то, при котором значение $r(f_t, h_{t+1})$ максимально. После этого процесс переходит на шаг $t + 1$ и повторяется.

Жадный алгоритм не смотрит в будущее и не пытается оптимизировать траекторию целиком, поэтому в общем случае он не приводит к глобальному оптимуму. Однако он работает в любой конкретной постановке. Достаточно конкретизировать операторы $\mathbf{H}_t$, $\mathbf{P}_t$, награду r и условие g , и жадная стратегия восстанавливается из общей схемы автоматически.

В Разделе 3 показано, что в исходной постановке наивная жадная стратегия не является удовлетворительным решением. На задаче прогнозирования цен такой алгоритм максимизирует локальную награду модели и одновременно ведет к оттоку пользователей. В пределе активная выборка пустеет и система перестает работать, то есть наступает деградация. Чтобы избежать такого исхода, в работе предлагается более аккуратное управление. В условие g помимо требования на сохранение петли добавляется зависимость от наблюдаемой выборки $\hat{f}_t$. После такой поправки жадный алгоритм отказывается от тех значений u_t , при которых среда деградирует, и в Разделе 3 показано, что эта стратегия сохраняет рост локальных метрик и не разрушает систему.

2.6. Непустота множества допустимых управлений

Чтобы постановка имела смысл, на каждом шаге множество допустимых управлений должно быть не пусто.

Предположение 1. *Начальное состояние системы (f_0, h_0) удовлетворяет условию $g(f_0, h_0) \leq 0$.*

Утверждение 1. Пусть нулевое управление не меняет модель: для всех $\mathbf{H}_t \in \mathbf{H}$ выполнено $\mathbf{H}_t(f_t, h_t, 0) = h_t$. Пусть также при неизменной модели оператор среды сохраняет допустимость: если $g(f, h) \leq 0$, то $g(\mathbf{P}_t(f, h), h) \leq 0$ для всех t и $\mathbf{P}_t \in \mathbf{P}$. Тогда при выполнении Предположения 1 на каждом шаге t управление $u_t = 0$ допустимо.

Доказательство. См. Приложение A.1. □

Предположение 1 есть стандартное требование к стартовой точке: система запускается в работоспособном режиме, иначе постановка (3)–(5) несовместна уже на первом шаге. Второе условие Утверждения 1 формализует то, что без вмешательства петля обратной связи сама по себе не выводит систему из допустимого множества.

В обоих сюжетах работы оба условия выполнены тривиально. В прогнозировании цен (подраздел 3.1) система запускается с полной активной выборкой N_0 , и оба варианта условия g , наивный (10) и аккуратный (11), в этой точке выполнены автоматически. При $u_t = 0$ покупатель видит честный прогноз, активная выборка не сокращается ниже порога δ . В Generative Replay условие g задается достижимостью уровня ошибки ε_t . При $u_t = 0$ функционал обучения сводится к слагаемому повторения с минимумом в текущей точке, поэтому $\mathcal{L}_t^*(0) = 0 < \varepsilon_t$ независимо от оператора среды.

Утверждение 1 замыкает корректность жадного алгоритма из подраздела 2.5: на каждом шаге множество допустимых управлений не пусто.

3. Основные результаты

В этом разделе общая постановка из Раздела 2 применяется к двум сюжетам. В подразделе 3.1 рассмотрена задача прогнозирования цен с эффектом обратной связи. Показано, что наивный жадный алгоритм выводит систему в нерабочий режим, и предложена модификация условия g , которая возвращает систему в работоспособный режим. В подразделе 3.2 тот же формализм применен к методу Generative Replay в задаче непрерывного обучения и получены оценки средней ошибки модели, обратная задача восстановления расписания по целевым весам и спектральная теория финальной ошибки в квадратичном приближении.

3.1. Деградация системы при прогнозировании цен

Модель учится предсказывать цены на сделках, ее прогноз используется как рекомендация покупателю, а решения покупателей формируют активную выборку на следующих шагах. Это типичная система с петлей обратной связи. Цель управления состоит в увеличении средней цены сделки. В работе показано, что прямолинейное применение жадного алгоритма ведет к оттоку пользователей, и предложено аккуратное условие g , которое возвращает систему в работоспособный режим.

3.1.1. Конкретизация общей постановки

Состояние среды на шаге t задается активной выборкой $(\mathbf{X}_t, \mathbf{y}_t)$ длины N_t . Каждый элемент есть пара из признаков объекта недвижимости и его цены. Плотность f_t есть эмпирическая плотность этой выборки. Веса модели регрессии цен на шаге t обозначаются через θ^t , их плотность через h_t . Модель $m_{\theta^t}(\mathbf{x})$ дает прогноз цены по признакам $\mathbf{x}$. Управление $u_t \in \mathbb{R}$ задает надбавку к прогнозу. Рекомендация покупателю на шаге t имеет вид

$$z_t = m_{\theta^t}(\mathbf{x}) + u_t. \quad (6)$$

Оператор обучения $\mathbf{H}_t$ дообучает модель на текущей активной выборке. Дообучение происходит не на каждом шаге, а раз в τ шагов:

$$h_{t+1} = \begin{cases} h_t, & t \bmod \tau \neq 0, \\ \arg \min_{\theta} \sum_{(\mathbf{x}, y) \in (\mathbf{X}_t, \mathbf{y}_t)} \mathcal{L}(m_{\theta}(\mathbf{x}), y), & t \bmod \tau = 0, \end{cases} \quad (7)$$

где τ обозначает период переобучения, а $\mathcal{L}$ обозначает функцию потерь регрессии.

Оператор реакции среды $\mathbf{P}_t$ моделирует решения покупателей. Случайно выбирается индекс $i \sim U(1, N_0)$, и покупателю предлагается цена $z_t = m_{\theta^t}(\mathbf{x}_i) + u_t$. С вероятностью

$$p_t \propto \exp\left[-\frac{z_t - y_i^0}{y_i^0}\right], \quad (8)$$

где y_i^0 обозначает исходную цену объекта i до начала эксперимента, покупатель соглашается на сделку, и пара $(\mathbf{x}_i, z_t)$ заменяет соответствующий элемент активной выборки. С вероятностью $1 - p_t$ покупатель отказывается, и индекс i удаляется. Размер активной выборки после такого шага либо сохраняется ($N_{t+1} = N_t$ при согласии), либо уменьшается на единицу ($N_{t+1} = N_t - 1$ при отказе).

Функция награды отражает цель управления: максимизировать среднюю цену состоявшихся сделок,

$$r(f_t, h_{t+1}) = \mathbb{E}_{(\mathbf{x}, y) \sim f_t} [m_{\theta^{t+1}}(\mathbf{x}) + u_t]. \quad (9)$$

Функция g кодирует сохранение петли обратной связи. Простейший вариант имеет вид ограничения

$$g(f_t, h_{t+1}) = -\log p_t \leq 0, \quad (10)$$

которое требует, чтобы вероятность согласия покупателя не падала ниже единицы. Это условие следит за тем, чтобы по крайней мере один пользователь продолжал покупать, и в этом смысле сохраняет саму петлю.

3.1.2. Жадная стратегия и эффект деградации

В принятых обозначениях жадная стратегия из подраздела 2.5 имеет следующий вид. На шаге t среди значений u_t , при которых выполнено (10), выбирается то, при котором значение (9) максимально. Содержательно управление поднимает цену настолько, насколько позволяет ограничение на вероятность согласия.

Описанная стратегия работает на коротком горизонте. Локальные метрики модели, например R^2 предсказания, растут, так как модель учится на собственных рекомендациях и легко их воспроизводит. Однако число активных

пользователей убывает. На каждом шаге часть покупателей отказывается от сделки и покидает систему. Со временем N_t падает к нулю, и при $N_t = 0$ система перестает работать.

В этой ситуации управление формально удовлетворяет ограничению (10) и достигает максимума функции награды. Однако само ограничение не учитывает, что вероятность p_t соответствует одному выбранному пользователю, а остальная активная выборка может быть в это же время неудовлетворена. То есть наивное g не следит за тем, что система может деградировать.

3.1.3. Аккуратное управление через зависимость от наблюдаемой выборки

Чтобы избежать деградации, изменим условие g . Включим в него зависимость от наблюдаемого размера активной выборки N_t . Достаточно потребовать, чтобы размер выборки на следующем шаге не убывал быстрее заданного порога $\delta > 0$:

$$g(f_t, h_{t+1}) = \delta - \frac{N_{t+1}}{N_t} \leq 0. \quad (11)$$

Поскольку N_{t+1} есть случайная величина с распределением, зависящим от (f_t, h_{t+1}, u_t) , условие (11) понимается в стохастическом смысле (4) с заранее выбранным уровнем риска.

Содержательно поправка отражает простую идею. Даже если на одном шаге покупатель согласен на сделку, нужно следить за тем, чтобы поток пользователей не иссякал в долгосрочной перспективе. Если выборка N_t начинает убывать, надбавка u_t уменьшается, и стратегия становится осторожнее. Через петлю обратной связи модель видит только те цены, которые покупатели готовы платить, и в долгосрочной перспективе средняя цена сделок повышается медленнее, но без потери самой системы.

Условие (11) автоматически влечет наивное условие (10). Если за один шаг размер активной выборки не убывает быстрее заданного порога δ , значит хотя бы доля $1 - \delta$ покупателей соглашается на сделку. В среднем это означает, что вероятность согласия p_t ограничена снизу величиной порядка $1 - \delta$. То есть условие на N_{t+1}/N_t является более сильным, чем требование положительности p_t , и отдельно следить за $\log p_t$ не нужно.

3.1.4. Обсуждение

Содержательное предсказание подраздела 3.1 проверяется численно. Эксперимент на синтетических данных по образцу датасета California Housing [38] подтверждает обе тенденции. Жадная стратегия с наивным условием (10) максимизирует локальную метрику R^2 и одновременно ведет к убыванию активной выборки N_t до нуля. Жадная стратегия с аккуратным условием (11) удерживает N_t на стабильном уровне, R^2 растет медленнее, но система не разрушается. Подробное описание схемы эксперимента, выбор параметров и результирующие кривые приведены в подразделе 4.1.

Аккуратное управление формально не выходит за рамки жадного алгоритма. Замена (10) на (11) есть переход к другому условию g в той же общей постановке (3)–(5), после чего жадный шаг подраздела 2.5 с новым g дает аккуратную стратегию. То есть аккуратное управление получается из жадного добавлением одной проверки на устойчивость наблюдаемой выборки, и его выделение в отдельную процедуру отражает не смену алгоритма, а уточнение функции g .

В следующем подразделе формализм применяется к Generative Replay: пространство задач многомерное, оператор обучения нелинейный, условие g требует достижения заданного уровня внутренней оптимизации. Этот сюжет дает замкнутые оценки средней ошибки и связь с теорией стохастической аппроксимации.

3.2. Generative Replay в задаче непрерывного обучения

Generative Replay есть метод борьбы с катастрофическим забыванием при последовательном обучении модели на потоке задач [15]. На каждом шаге обучающая выборка собирается из двух источников. Часть примеров приходит из новой задачи, остальные синтезируются генератором по уже изученным задачам и помечаются ответами текущей модели через самодистилляцию. Доля новых данных $u_t \in [0, 1]$ становится управлением и переменной оптимизации в настоящей работе. В этом подразделе общая постановка из Раздела 2 применяется к Generative Replay. Сначала конкретизируются операторы $\mathbf{H}_t$, $\mathbf{P}_t$ и условие g . Далее последовательно получаются достаточные условия допустимости управления, верхняя оценка средней ошибки модели для произвольного расписания, обратная задача восстановления расписания по целевым весам задач, замкнутые

формулы шага и спектральная оценка финальной ошибки, разложение средней ошибки на компоненты смещения и дисперсии и связь с классической теорией стохастической аппроксимации, а также адаптивное расписание и жадный выбор порядка задач.

3.2.1. Конкретизация общей постановки

Пусть дана последовательность задач $D_1, D_2, \dots, D_T$. Каждая задача задает свое распределение пар $(\mathbf{x}, y)$. Состояние системы на шаге t задается парой (f_t, h_t) . Плотность f_t разделяется на две части. Первая часть f_t^1 соответствует распределению новой задачи D_{t+1} . Вторая часть f_t^2 задается генератором G_t , обученным на прошлых задачах. Пары из второй части имеют вид $(\mathbf{x}, m_{\theta^t}(\mathbf{x}))$ с $\mathbf{x} \sim G_t$. Плотность h_t , как и в общей постановке, описывает веса модели θ^t .

Управление $u_t \in [0, 1]$ задает долю новых данных в обучающей выборке. С вероятностью u_t из новой задачи берется пара $(\mathbf{x}, y) \sim D_{t+1}$. С вероятностью $1 - u_t$ из генератора берется пара $(\mathbf{x}', m_{\theta^t}(\mathbf{x}'))$ с $\mathbf{x}' \sim G_t$.

Оператор обучения модели $\mathbf{H}_t$ задается минимизацией функционала

$$\mathcal{L}_{\text{train}}(\theta, f_t, u_t) = u_t \cdot \mathbb{E}_{(\mathbf{x}, y) \sim D_{t+1}} [\mathcal{L}(m_{\theta}(\mathbf{x}), y)] + (1 - u_t) \cdot \mathbb{E}_{\mathbf{x}' \sim G_t} [\mathcal{L}(m_{\theta}(\mathbf{x}'), m_{\theta^t}(\mathbf{x}'))], \quad (12)$$

где $\mathcal{L}$ обозначает функцию потерь. Минимизация выполняется итерационным методом первого порядка из начального приближения $\theta^{(0)} \sim h_t$. Полученные веса θ^{t+1} определяют новую плотность h_{t+1} . Оптимальное значение функционала на шаге t обозначается

$$\mathcal{L}_t^*(u_t) = \min_{\theta} \mathcal{L}_{\text{train}}(\theta, f_t, u_t). \quad (13)$$

Оператор реакции среды $\mathbf{P}_t$ описывает переход к следующей задаче. Меняется целевое распределение, теперь f_{t+1}^1 есть распределение задачи D_{t+2} . Также обновляется генератор G_{t+1} так, чтобы в его носитель попадала задача D_{t+1} , изученная на текущем шаге.

Функция награды записывается через среднюю ошибку модели по всем изученным задачам:

$$\mathcal{L}_{t+1} = \frac{1}{t+1} \sum_{s=1}^{t+1} \mathcal{L}_s(\theta^{t+1}), \quad \mathcal{L}_s(\theta) = \mathbb{E}_{(\mathbf{x}, y) \sim D_s} [\mathcal{L}(m_{\theta}(\mathbf{x}), y)]. \quad (14)$$

Цель состоит в минимизации $\mathcal{L}_T$. Это эквивалентно максимизации соответствующей награды $r = -\mathcal{L}_T$ в общей постановке.

Условие g в Generative Replay задает требование на сходимость внутренней оптимизации. Введем заранее выбранный уровень точности $\varepsilon_t > 0$. Управление u_t называется ε_t -допустимым, если

$$g(f_t, h_{t+1}, u_t) = \mathcal{L}_t^*(u_t) - \varepsilon_t \leq 0. \quad (15)$$

То есть управление допустимо, если процедура обучения при балансе $(u_t, 1 - u_t)$ способна достичь ошибки не хуже ε_t .

Множество допустимых управлений на каждом шаге не пусто по Утверждению 1: при $u_t = 0$ функционал (12) сводится к слагаемому повторения с метками самодистилляции, в точке $\theta = \theta^t$ обращается в нуль, и условие $\mathbf{H}_t(f_t, h_t, 0) = h_t$ выполнено. Тогда $\mathcal{L}_t^*(0) = 0 < \varepsilon_t$, и нулевое управление удовлетворяет (15).

Пример. Не любое $u_t \in [0, 1]$ допустимо. Возьмем скалярную модель $m_\theta(x) = \theta$ с MSE функцией ошибки. Пусть Оптимумы задач $\theta_1^* = -1$ и $\theta_2^* = +1$, текущую модель $\theta^t = -1$ и точный генератор G_1 . Тогда $\mathcal{L}_t^*(u_t) = 2u_t(1 - u_t)$, и при $u_t = 1/2$ значение $\mathcal{L}_t^* = 1/2$. Если $\varepsilon_t < 1/2$, управление $u_t = 1/2$ недопустимо: модель встает посередине между оптимумами. Допустимы только u_t близкие к 0 или к 1.

3.2.2. Достаточные условия допустимости управления

Допустимость управления $u_t = 0$ ничего не говорит про другие значения u_t . Чтобы получить достаточные условия для произвольного u_t , привлекаются предположения о функции потерь и об обучающем отображении.

Условие через липшицевость потерь. Предположим, что функция потерь липшицева по параметрам модели.

Предположение 2. Существует константа $L_{loss} > 0$ и метрика $d(\cdot, \cdot)$ в пространстве параметров Θ такие, что для любых $\theta_1, \theta_2 \in \Theta$ и любых $\mathbf{x} \in \mathcal{X}$, $z \in \mathcal{Y}$

$$|\mathcal{L}(m_{\theta_1}(\mathbf{x}), z) - \mathcal{L}(m_{\theta_2}(\mathbf{x}), z)| \leq L_{loss} \cdot d(\theta_1, \theta_2).$$

Метрика $d(\cdot, \cdot)$ есть расстояние между наборами параметров модели. В естественных случаях это евклидово расстояние $d(\boldsymbol{\theta}_1, \boldsymbol{\theta}_2) = \|\boldsymbol{\theta}_1 - \boldsymbol{\theta}_2\|$ или его взвешенный аналог $\|\boldsymbol{\theta}_1 - \boldsymbol{\theta}_2\|_H$ с положительно определенной матрицей H .

Это предположение стандартно в теории обучения. Оно применяется в оценках устойчивости алгоритмов [39] и сходимости стохастического градиентного спуска [40]. Для среднеквадратичной потери с ограниченным выходом модели и для перекрестной энтропии с ограниченными логитами оно выполнено с явной константой L_{loss} .

Теорема 1. Пусть выполнено Предположение 2. Управление $u_t \in (0, 1)$ является ε_t -допустимым, если существует $\boldsymbol{\theta}^{t+1} \in \Theta$, для которого одновременно

$$\mathcal{L}_{t+1}(\boldsymbol{\theta}^{t+1}) \leq \frac{\varepsilon_t}{2u_t}, \quad d(\boldsymbol{\theta}^{t+1}, \boldsymbol{\theta}^t) \leq \frac{\varepsilon_t}{2(1 - u_t)L_{\text{loss}}}.$$

Доказательство. См. Приложение Б.1. □

У этой формулировки есть ограничения. Веса $\boldsymbol{\theta}^{t+1}$ требуются в фиксированной окрестности $\boldsymbol{\theta}^t$, что трудно гарантировать для стохастических процедур обучения. Оценка зависит от константы Липшица L_{loss} , которая на практике обычно недоступна. Кроме того, сравниваются веса с двух разных шагов, тогда как естественнее сравнивать выходы одного шага обучения на близких выборках.

Условие через устойчивость оператора обучения. Альтернативный путь опирается на устойчивость оператора обучения. Зафиксируем шаг t и оператор $\mathbf{H}_t \in \mathbf{H}$ из постановки, действующий на выборке длины m . При значении управления $u \in [0, 1]$ выборка состоит из um объектов новой задачи и $(1 - u)m$ объектов повторения. Поэтому выборки, отвечающие $u = 0$ и $u = u_t$, отличаются не более чем в $k_t = u_t m$ позициях.

Определение 1 (Устойчивость к замене одного примера [39]). Оператор обучения $\mathbf{H}_t$ обладает устойчивостью к замене одного примера с константой $\beta_m \geq 0$, если для любых выборок S, S' длины m , отличающихся ровно в одном элементе,

$$\sup_z |\mathcal{L}(\mathbf{H}_t(S), z) - \mathcal{L}(\mathbf{H}_t(S'), z)| \leq \beta_m.$$

Это понятие введено в работе [39]. Там же для регуляризованной эмпирической минимизации риска получена оценка $\beta_m = \mathcal{O}(1/m)$. Для стохастического

градиентного спуска в выпуклом и невыпуклом случаях аналогичные оценки доказаны в работе [40], что покрывает большинство практически используемых алгоритмов обучения. Поэтому в дальнейшем считаем, что класс алгоритмов с $\beta_m = \mathcal{O}(1/m)$ нетривиально широк.

Лемма 1. *Если выборки S, S' длины m отличаются не более чем в k позициях, то*

$$\sup_z |\mathcal{L}(\mathbf{H}_t(S), z) - \mathcal{L}(\mathbf{H}_t(S'), z)| \leq k\beta_m.$$

Доказательство. См. Приложение Б.2. □

Теорема 2. *Пусть оператор $\mathbf{H}_t \in \mathbf{H}$ устойчив с константой β_m , а $\boldsymbol{\theta}^{t+1}(u_t)$ — результат применения $\mathbf{H}_t$ к выборке. Управление u_t является ε_t -допустимым, если*

$$\mathcal{L}_{t+1}(\boldsymbol{\theta}^{t+1}(u_t)) \leq \frac{\varepsilon_t}{2u_t}, \quad u_t m \beta_m \leq \frac{\varepsilon_t}{2(1 - u_t)}.$$

Доказательство. См. Приложение Б.3. □

Эта формулировка устраняет недостатки Теоремы 1. Константа β_m известна для широкого класса алгоритмов [39, 40]. Для алгоритма минимизации эмпирического риска с регуляризацией Тихонова $\beta_m = \mathcal{O}(1/m)$, и условие на u_t принимает простой вид $u_t \leq \varepsilon_t / (2B + \varepsilon_t)$ при $\beta_m \leq B/m$. Это явная верхняя граница на u_t без знания константы Липшица.

Теоремы 1 и 2 формируют пару с Теоремой 3 из следующей подсекции. Маленький ε_t улучшает верхнюю оценку средней ошибки, но сужает диапазон допустимых u_t : например, в Теореме 2 граница $u_t \leq \varepsilon_t / (2B + \varepsilon_t)$ при $\varepsilon_t \rightarrow 0$ обращается в нуль. Поэтому выбор ε_t всегда есть компромисс между точностью оценки и достижимостью допустимости.

3.2.3. Верхняя оценка средней ошибки и обратная задача

Допустимость дает условие на одно управление u_t . Чтобы оценить качество модели после всего процесса, нужно связать средние ошибки на разных шагах. Введем веса задач, индуцированные расписанием.

Определение 2. *По расписанию $(u_0, u_1, \dots, u_{t-1})$ определим веса задач:*

$$w_{1,t+1} = \prod_{r=1}^t (1 - u_r), \quad w_{s,t+1} = u_{s-1} \prod_{r=s}^t (1 - u_r), \quad 2 \leq s \leq t+1.$$

Лемма 2. Веса из Определения 2 неотрицательны и в сумме дают единицу.

Доказательство. См. Приложение B.1. □

Взвешенная средняя ошибка модели после шага t определяется как $\mathcal{L}_{t+1}^{(w)} = \sum_{s=1}^{t+1} w_{s,t+1} \mathcal{L}_s(\boldsymbol{\theta}^{t+1})$. При расписании $u_t = 1/(t+1)$ веса равномерны, $w_{s,t+1} = 1/(t+1)$, и $\mathcal{L}_{t+1}^{(w)}$ совпадает с обычной средней (14).

Главное условие на функцию потерь, при котором удастся доказать верхнюю оценку средней ошибки, есть неравенство треугольника. Сформулируем его как отдельное предположение.

Предположение 3. Для любого датасета D_s функционал риска $\mathcal{L}_s$ удовлетворяет неравенству треугольника по предсказанию модели: для любых $\boldsymbol{\theta}_1, \boldsymbol{\theta}_2 \in \Theta$ и любой выборки $\mathbf{x} \sim p_s$

$$\mathcal{L}_s(\boldsymbol{\theta}_1) \leq \mathbb{E}_{\mathbf{x} \sim p_s} [\mathcal{L}(m_{\boldsymbol{\theta}_1}(\mathbf{x}), m_{\boldsymbol{\theta}_2}(\mathbf{x}))] + \mathcal{L}_s(\boldsymbol{\theta}_2).$$

Среднеквадратичная потеря удовлетворяет ему как квадрат евклидовой нормы. Абсолютная потеря и расстояние в произвольной норме удовлетворяют ему по построению. Кросс энтропия и расстояние Кульбака-Лейблера подчиняются неравенству треугольника по выпуклости и неотрицательности. Соответственно, Предположение 3 не сужает класс задач последующей теории.

Из Предположения 3 и липшицевости (Предположение 2) получается базовая лемма, связывающая ошибку модели $\boldsymbol{\theta}^{t+1}$ на задаче D_s с ошибкой на функционале повторения, с $\mathcal{L}_s(\boldsymbol{\theta}^t)$ и с расхождением генератора задачи D_s .

Лемма 3 (Неравенство треугольника для потерь). Пусть выполнены Предположения 2 и 3. Обозначим через p_s плотность признаков задачи D_s , через p_{G_t} плотность генератора G_t . Тогда для любого $s \leq t$

$$\mathcal{L}_s(\boldsymbol{\theta}^{t+1}) \leq \mathbb{E}_{\mathbf{x} \sim G_t} [\mathcal{L}(m_{\boldsymbol{\theta}^{t+1}}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x}))] + \mathcal{L}_s(\boldsymbol{\theta}^t) + L_{\text{loss}} \cdot d(\boldsymbol{\theta}^{t+1}, \boldsymbol{\theta}^t) \cdot \mathcal{E}_{\text{gen}}(s, t),$$

где ошибка генератора задается выражением

$$\mathcal{E}_{\text{gen}}(s, t) = \int |p_s(\mathbf{x}) - p_{G_t}(\mathbf{x})| d\mathbf{x}.$$

Доказательство. См. Приложение B.2. □

Слагаемое $\mathcal{E}_{\text{gen}}(s, t)$ обращается в нуль при $p_{G_t} = p_s$ и измеряет, насколько генератор G_t отклоняется от истинной плотности признаков задачи D_s . Взвешенная сумма этих ошибок $\bar{\mathcal{E}}_t = L_{\text{loss}} d(\boldsymbol{\theta}^{t+1}, \boldsymbol{\theta}^t) \sum_{s=1}^t w_{s,t} \mathcal{E}_{\text{gen}}(s, t)$ собирает накопленную ошибку генератора по всем изученным задачам с весами расписания.

Теорема 3. Пусть на каждом шаге выполнены Предположения 2, 3 и управление u_t является ε_t -допустимым. Тогда взвешенная средняя ошибка модели удовлетворяет рекуррентному неравенству

$$\mathcal{L}_{t+1}^{(w)} \leq \varepsilon_t + (1 - u_t) \mathcal{L}_t^{(w)} + \bar{\mathcal{E}}_t.$$

После рекурсивной подстановки

$$\mathcal{L}_{t+1}^{(w)} \leq \sum_{j=0}^t \left(\prod_{r=j+1}^t (1 - u_r) \right) \varepsilon_j + \sum_{j=1}^t \left(\prod_{r=j+1}^t (1 - u_r) \right) \bar{\mathcal{E}}_j.$$

Доказательство. См. Приложение B.3. □

Произведения $\prod_{r=j+1}^t (1 - u_r)$ показывают, как быстро забывается допустимость на шаге j . При больших u_r след прошлых шагов исчезает экспоненциально, что соответствует более агрессивному управлению. При идеальном генераторе $\bar{\mathcal{E}}_t = 0$ и оценка зависит только от порогов допустимости ε_t .

Обсуждение. Теорема 3 выделяет два независимых источника финальной ошибки. Первый есть порог допустимости ε_t , регулируемый выбором алгоритма и числа эпох. Второй есть расхождение генератора $\bar{\mathcal{E}}_t$, не контролируемое расписанием. Качество генератора деградирует с ростом числа задач [15], поэтому любое расписание имеет предельное качество, не улучшаемое выбором u_t .

Чем меньше ε_t , тем туже верхняя оценка средней ошибки и тем ближе модель к траектории совместного обучения. Однако малое ε_t усложняет проверку условия ε_t -допустимости: при заданном алгоритме обучения и фиксированной длине выборки достижимый уровень $\mathcal{L}_t^*(u_t)$ ограничен снизу, и допустимыми остаются только узкие интервалы u_t . Конструктивные условия на u_t , при которых ε_t -допустимость гарантирована, даны Теоремами 1 и 2. Они вместе с Теоремой 3 задают баланс между качеством финальной оценки и допустимостью.

Сама форма множителей $\prod_{r=j+1}^t (1 - u_r)$ объясняет, как разные расписания управляются с прошлыми задачами. При $u_t = 1/(t + 1)$ произведение телекопирует, $\prod_{r=j+1}^t r/(r + 1) = (j + 1)/(t + 1)$, и след допустимости на шаге j убывает обратно пропорционально t , давая равномерные веса задач в финальной оценке. При постоянном $u_t = u \in (0, 1)$ произведение равно $(1 - u)^{t-j}$, и след убывает экспоненциально по $t - j$: ранние задачи забываются геометрически быстро, а финальная ошибка определяется поздними задачами. Эти два режима эмпирически разделяются в подразделе 4.2.2: расписание $u_t = 1/(t + 1)$ с равномерными весами выходит на уровень совместного обучения, постоянное расписание оставляет ненулевой остаток за счет систематической просадки ранних задач.

Обратная задача. Веса $\alpha_s = w_{s,T}$ имеют интерпретацию вклада задачи D_s в финальную модель. Естественно задавать α_s по содержательным соображениям (например, равные веса по всем задачам или повышенный вес у редких задач) и затем восстанавливать расписание.

Утверждение 2. Пусть $\alpha_1, \dots, \alpha_T > 0$ и $\sum_{s=1}^T \alpha_s = 1$. Обозначим $S_k = \sum_{s=1}^k \alpha_s$. Тогда управления

$$u_t = \frac{\alpha_{t+1}}{S_{t+1}}, \quad t = 0, 1, \dots, T - 1, \quad (16)$$

порождают веса $w_{s,T} = \alpha_s$ для всех s .

Доказательство. См. Приложение В.4. □

Формула (16) дает прямой и однозначный мост между интерпретируемой постановкой через вклад задач в финальную модель и инвариантной постановкой через расписание. Равным весам $\alpha_s = 1/T$ соответствует $u_t = 1/(t + 1)$. Постоянному управлению $u_t = u$ соответствуют геометрические веса $\alpha_s = u(1 - u)^{T-s}$ при $s \geq 2$.

Обсуждение. Требования к финальной модели обычно формулируются в терминах весов α_s : равное представление задач, повышенный вес редких задач, приоритет новой задачи до целевой доли. Утверждение 2 превращает такое требование в явное расписание u_t . Геометрический случай $u_t = u$ отвечает

скользящему окну с быстрым забыванием ранних задач, равномерные веса $\alpha_s = 1/T$ дают $u_t = 1/(t+1)$, согласованное со стохастической аппроксимацией Роббинса-Монро.

В Теореме 3 оценка выражена через значения $\mathcal{L}_t^*(u_t)$, для которых в общей постановке нет замкнутой формулы. При квадратичном приближении функции потерь это значение выражается явно через гессианы задач H_{t+1} и операционный гессиан повторения Σ_t .

3.2.4. Спектральная теория ошибки в квадратичном приближении

Чтобы получить замкнутые формулы для $\mathcal{L}_t^*(u_t)$ и финальной ошибки, перейдем к квадратичному приближению функции потерь.

Обозначим через $\theta_s^* = \arg \min_{\theta} \mathcal{L}_s(\theta)$ оптимум задачи D_s , через $\varepsilon_s^* = \mathcal{L}_s(\theta_s^*)$ минимальную ошибку на D_s и через $H_s = \nabla^2 \mathcal{L}_s(\theta_s^*)$ гессиан задачи в оптимуме. Через $R_t(\theta) = \mathbb{E}_{\mathbf{x} \sim G_t} [\mathcal{L}(m_{\theta}(\mathbf{x}), m_{\theta^t}(\mathbf{x}))]$ обозначим функционал повторения, через $\Sigma_t = \nabla^2 R_t(\theta^t)$ его операционный гессиан в текущей точке. Положим $\Delta_t = \theta_{t+1}^* - \theta^t$ для разницы между оптимумом новой задачи и текущей моделью.

Предположение 4. *Функционал потерь и функционал повторения квадратичны вокруг своих минимумов:*

$$\mathcal{L}_s(\theta) = \varepsilon_s^* + \frac{1}{2}(\theta - \theta_s^*)^\top H_s(\theta - \theta_s^*), \quad R_t(\theta) = \frac{1}{2}(\theta - \theta^t)^\top \Sigma_t(\theta - \theta^t).$$

Квадратичное приближение точно справедливо для линейной регрессии со среднеквадратичной потерей и дает разложение Тейлора второго порядка с остатком $O(\|\theta - \theta_s^*\|^3)$ для нелинейных моделей вблизи минимума. На нем основаны Ньютоновские и квазиньютоновские методы и квадратичный случай стохастической аппроксимации [19].

Лемма 4. *Пусть выполнено Предположение 4 и внутренняя оптимизация в (13) точна. Тогда*

$$\theta^{t+1} = M_t^{-1} [u_t H_{t+1} \theta_{t+1}^* + (1 - u_t) \Sigma_t \theta^t], \quad M_t = u_t H_{t+1} + (1 - u_t) \Sigma_t. \quad (17)$$

Доказательство. См. Приложение Г.1. □

Новая модель θ^{t+1} есть взвешенное среднее оптимума новой задачи θ_{t+1}^* и предыдущей модели θ^t , где веса определяются гессианами H_{t+1} и Σ_t . Форму-

ла (17) переводит шаг Generative Replay в линейную алгебру и служит основой всех дальнейших результатов.

Лемма 5. В условиях Леммы 4 при расписании $u_t = 1/(t+1)$ значение функционала имеет вид

$$\mathcal{L}_t^*(u_t) = \frac{\varepsilon_{t+1}^*}{t+1} + \pi_t, \quad \pi_t = \frac{t}{2(t+1)} \Delta_t^\top H_{t+1} (H_{t+1} + t\Sigma_t)^{-1} \Sigma_t \Delta_t. \quad (18)$$

Доказательство. См. Приложение Г.2. □

Обсуждение. Величина π_t есть спектральный конфликт между новой задачей и накопленным знанием модели. Он мал при $\Delta_t \rightarrow 0$ (задачи структурно близки) и при $H_{t+1}\Sigma_t = 0$ (носители гессианов ортогональны).

Подставляя (18) в Теорему 3 с равномерными весами, получаем основной результат подраздела.

Теорема 4 (Спектральная оценка средней ошибки). При Предположении 4, точной внутренней оптимизации в (13), идеальном генераторе ($\bar{\mathcal{E}}_t = 0$) и расписании $u_t = 1/(t+1)$ выполнено

$$\mathcal{L}_T \leq \bar{\varepsilon}^* + \frac{1}{T} \sum_{t=0}^{T-1} (t+1)\pi_t, \quad \bar{\varepsilon}^* = \frac{1}{T} \sum_{s=1}^T \varepsilon_s^*. \quad (19)$$

Доказательство. См. Приложение Г.3. □

Обсуждение. Оценка разделяет финальную ошибку на два слагаемых: $\bar{\varepsilon}^*$ — нижняя граница, заданная сложностью задач, и $\frac{1}{T} \sum (t+1)\pi_t$ — накопленный спектральный конфликт. Множитель $(t+1)$ делает конфликт на поздних шагах критичнее, но при расписании $u_t = 1/(t+1)$ величина $\pi_t \sim 1/t$ и рост компенсируется. Структура оценки проверяется на синтетике: в подразделе 4.2.2 наблюдается монотонный выход $\mathcal{L}_t$ на $\bar{\varepsilon}^*$, в подразделе 4.2.3 условие $H_{t+1}\Sigma_t = 0$ обращает π_t в нуль, в подразделе 4.2.4 финальная ошибка следует за $\sum_t \|\Delta_t\|^2$ при разном порядке задач.

Из спектральной оценки следуют два структурных результата.

Следствие 1 (Условие нулевого конфликта). Если $H_{t+1}\Sigma_t = 0$ для всех $t = 1, \dots, T-1$, то $\pi_t = 0$ и $\mathcal{L}_T = \bar{\varepsilon}^*$.

Доказательство. См. Приложение Г.4. □

Условие $H_{t+1}\Sigma_t = 0$ означает ортогональность колоночных пространств гессианов. Новая задача имеет кривизну только в направлениях, где гессиан функционала повторения равен нулю, и наоборот. Содержательно это структурное разделение задач по подпространствам параметров. Эмпирическая проверка приведена в подразделе 4.2.3, где задачи сконструированы так, что оптимум каждой задачи лежит на отдельной координате общего ортогонального базиса.

Теорема 5 (Безусловная спектральная оценка). *Пусть в условиях Теоремы 4 дополнительно $\|H_{t+1}\|_{op}, \|\Sigma_t\|_{op} \leq L$ и $\|\Delta_t\| \leq D$. Тогда*

$$\mathcal{L}_T \leq \bar{\varepsilon}^* + \frac{LD^2}{2}. \quad (20)$$

Доказательство. См. Приложение Г.5. □

Оценка (20) зависит только от спектральных норм гессианов и от диаметра траектории модели в пространстве параметров.

Обсуждение. Безусловная оценка выражает спектральный конфликт через две измеримые величины: спектральную норму гессианов L и диаметр траектории D . Оба показателя оцениваются из обучающих логов: L контролируется регуляризацией функции потерь, D зависит от разнообразия задач. При точной внутренней оптимизации оценка (20) не зависит ни от расписания, ни от порядка задач.

Сравнение с совместным обучением. Пусть θ^{joint} обозначают веса модели, обученной совместно на всех T задачах, а $\mathcal{L}_T^{\text{joint}}$ обозначает соответствующую среднюю ошибку. По определению $\mathcal{L}_T^{\text{joint}} \leq \mathcal{L}_T$ для любой траектории Generative Replay. Разность $\mathcal{L}_T - \mathcal{L}_T^{\text{joint}}$ выражается через отклонение финальной модели от θ^{joint} в гессиановой метрике $\bar{H}_T = (1/T) \sum_s H_s$. Источник этого отклонения локализован в несовпадении операционного Σ_t со структурным средним $\bar{H}_t = (1/t) \sum_{s \leq t} H_s$. Если $\Sigma_t = \bar{H}_t$ на каждом шаге, то Generative Replay воспроизводит траекторию совместного обучения и $\mathcal{L}_T = \mathcal{L}_T^{\text{joint}}$.

При однородных задачах (одинаковый гессиан) и независимых оптимумах шаг Generative Replay сводится к экспоненциальному скользящему среднему. В

этом частном случае смещение и дисперсия текущей модели выписываются в замкнутой форме, а сходимость GR связывается со стохастической аппроксимацией.

3.2.5. Bias–variance анализ и связь с классической теорией

При дополнительных предположениях шаг Generative Replay становится скалярным и приобретает прямое статистическое истолкование.

Предположение 5. Все задачи имеют одинаковый гессиан: $H_s = H$ для всех s , а операционный гессиан replay равен $\Sigma_t = H$.

Предположение описывает поток однородных задач: например, линейную регрессию с разными целевыми коэффициентами и одинаковой ковариацией признаков, или классификацию объектов одного типа с разными метками. Для разнородных задач анализ возвращается к спектральной оценке (19).

Замечание (Релаксация Предположения 5). Точное равенство $H_s = H$ можно ослабить до условий $\mathbb{E}[H_s] = H_*$ с независимыми и одинаково распределенными гессианами по задачам и $\|H_s - H_*\|_{\text{op}} \leq \varepsilon$ почти наверное. Прямое разложение $M_t^{-1} = H_*^{-1} + \mathcal{O}(\varepsilon)$ показывает, что bias-variance формула из Теоремы 6 сохраняется с поправками порядка ε . Естественный пример такого режима возникает в линейной регрессии со стандартизованными признаками $X_{ij} \sim \mathcal{N}(0, 1)$ независимо: эмпирический гессиан $\hat{H}_t = \frac{1}{n} X_t^\top X_t$ удовлетворяет $\mathbb{E}[\hat{H}_t] = I_d$ и $\|\hat{H}_t - I_d\|_{\text{op}} = O_p(\sqrt{d/n})$.

Предположение 6. Оптимумы задач независимы и одинаково распределены: θ_s^* имеют математическое ожидание μ^* и ковариацию C^* .

Это статистическая модель потока задач, в которой каждая задача есть случайная выборка из общего распределения, аналог независимых и одинаково распределенных наблюдений. Совместный оптимум μ^* выступает истинным параметром, оптимум θ_s^* выступает его зашумленной оценкой. Сходимость θ^t к μ^* сводится к стохастической аппроксимации Роббинса-Монро [19].

Лемма 6. Пусть выполнены Предположения 5 и 6. Тогда шаг Generative Replay из Леммы 4 принимает вид экспоненциального скользящего среднего

$$\theta^{t+1} = (1 - u_t)\theta^t + u_t\theta_{t+1}^*. \quad (21)$$

Доказательство. См. Приложение Д.1. □

Развертка рекурсии (21) из начального состояния $\boldsymbol{\theta}^0$ имеет вид

$$\boldsymbol{\theta}^t = \Pi_t \boldsymbol{\theta}^0 + \sum_{s=0}^{t-1} w_s^{(t)} \boldsymbol{\theta}_{s+1}^*, \quad \Pi_t = \prod_{s=0}^{t-1} (1 - u_s), \quad w_s^{(t)} = u_s \prod_{k=s+1}^{t-1} (1 - u_k).$$

Веса $w_s^{(t)}$ в сумме дают $1 - \Pi_t$, поэтому $\boldsymbol{\theta}^t$ есть выпуклая комбинация начального состояния и наблюдаемых оптимумов. В этом режиме шаг Generative Replay становится скалярным и совпадает с типовой итерацией стохастической аппроксимации. Это открывает доступ к классическим результатам Роббинса-Монро и используется в следующей Теореме 6 для замкнутого разложения средней ошибки.

Теорема 6 (Bias–variance разложение). *При Предположениях 5 и 6 для всех $t \geq 1$ выполнено*

$$\mathbb{E}[\boldsymbol{\theta}^t] - \mu^* = \Pi_t (\boldsymbol{\theta}^0 - \mu^*), \quad (22)$$

$$\text{Cov}(\boldsymbol{\theta}^t) = \left(\sum_{s=0}^{t-1} (w_s^{(t)})^2 \right) C^*, \quad (23)$$

$$\mathbb{E} \|\boldsymbol{\theta}^t - \mu^*\|^2 = \underbrace{\Pi_t^2 \|\boldsymbol{\theta}^0 - \mu^*\|^2}_{\text{смещение}^2} + \underbrace{\text{tr}(C^*) \sum_{s=0}^{t-1} (w_s^{(t)})^2}_{\text{дисперсия}}. \quad (24)$$

Доказательство. См. Приложение Д.2. □

Разложение (24) отражает классический баланс смещения и дисперсии. Смещение отвечает остатку начального состояния, а дисперсия отвечает накопленному шуму оптимумов задач.

Обсуждение. Разложение (24) различает три режима. Расписание $u_t = 1/(t+1)$ обнуляет обе компоненты со скоростью $\mathcal{O}(1/t)$. Постоянное $u_t = u$ убирает смещение экспоненциально, но удерживает дисперсию на стационарном уровне $\frac{u}{2-u} \text{tr}(C^*)$, монотонно растущем с u . Квадратичное $u_t = 1/(t+1)^2$ нарушает $\sum_t u_t = \infty$ и оставляет смещение на ненулевом плато. Выбор расписания опирается на горизонт обучения: при известном ограниченном T постоянное

расписание с малым u предпочтительнее за счет быстрого выхода на стационар, при неограниченном потоке $u_t = 1/(t + 1)$ остается единственным расписанием, обнуляющим обе компоненты. Подраздел 4.2.5 проверяет разложение на линейной рекурсии с независимыми оптимумами.

Теорема 7 (Условия сходимости в среднем квадратичном). *В условиях Теоремы 6:*

1. $P_t \rightarrow 0$ тогда и только тогда, когда $\sum_t u_t = \infty$.

2. Если дополнительно $u_t \rightarrow 0$, то $\sum_s (w_s^{(t)})^2 \rightarrow 0$.

Поэтому при $\sum_t u_t = \infty$ и $u_t \rightarrow 0$ выполнено $\mathbb{E}\|\theta^t - \mu^*\|^2 \rightarrow 0$.

Доказательство. См. Приложение Д.3. □

Условия теоремы совпадают с классическим требованием стохастической аппроксимации Роббинса–Монро [19]. Расписание $u_t = 1/(t+1)$ им удовлетворяет, что согласует Generative Replay с теорией стохастической аппроксимации.

Интерпретация расписания $u_t = 1/(t + 1)$. Расписание $u_t = 1/(t + 1)$ имеет в этой постановке особый смысл. При одинаковых гессианах задач и независимых измерениях такая последовательность весов воспроизводит оценку максимального правдоподобия для среднего μ^* по выборке оптимумов задач: апостериорная оценка совпадает с эмпирическим средним всех наблюдаемых θ_s^* . В этом режиме модель θ^t сходится к μ^* со скоростью $O(1/t)$ в среднем квадратичном, что согласуется с Теоремой 6. Другие расписания искажают информационные веса и не дают оценки, оптимальной в среднем квадратичном. Три режима из Теоремы 7 видны на графиках подраздела 4.2.5: расписание $u_t = 1/(t + 1)$ обнуляет смещение и дисперсию, постоянное расписание обнуляет смещение и выходит на стационарный уровень дисперсии, расписание $u_t = 1/(t + 1)^2$ нарушает $\sum_t u_t = \infty$ и оставляет смещение на плато.

3.2.6. Жадный порядок задач и адаптивное расписание

В предыдущих результатах расписание u_t и порядок прохождения задач были фиксированы. Сначала рассматривается выбор порядка задач, минимизирующий безусловную оценку (20). Затем обсуждается возможность адаптивного выбора расписания по наблюдаемому состоянию системы.

Жадный выбор порядка задач. При фиксированном расписании $u_t = 1/(t + 1)$ свобода в выборе порядка прохождения задач остается. По безусловной оценке (20) из Теоремы 5 верхняя оценка финальной ошибки зависит от перестановки $\sigma \in S_T$ только через сумму $\sum_t \|\Delta_t\|^2$, где $\Delta_t = \theta_{\sigma(t+1)}^* - \theta^t$. Эту сумму минимизирует жадная стратегия, выбирающая на каждом шаге задачу с ближайшим к текущей модели оптимумом:

$$\sigma_{\text{greedy}}(t + 1) = \arg \min_{s \notin U_t} \|\theta_s^* - \theta^t\|,$$

где U_t обозначает множество уже пройденных индексов задач. По построению жадная стратегия доставляет минимум правой части Теоремы 5 среди стратегий без знания будущих шагов.

В режиме точной внутренней оптимизации (Лемма 4) финальное состояние θ^T не зависит от порядка задач, поэтому жадный выбор не влияет на финальную ошибку. Эффект порядка локализован в канале неточной внутренней оптимизации. Эмпирическая проверка дана в подразделе 4.2.4, где жадная стратегия сравнивается со случайной и оптимальной (полный перебор).

Адаптивное расписание как направление дальнейшей работы. Расписания $u_t = 1/(t + 1)$ и постоянное $u_t = u$ задаются наперед, без обратной связи по наблюдаемому состоянию модели. Естественное направление развития подсказывают локальная квадратичная модель функционала $\mathcal{L}_{\text{train}}$. Зафиксируем шаг t и обозначим через $r_t = \mathcal{L}_{t+1}(\theta^t)$ ошибку текущей модели на новой задаче, через $g_t = \frac{1}{t} \sum_{s=1}^t \mathcal{L}_s(\theta^t)$ среднюю ошибку на изученных задачах. Обе величины наблюдаемы на отложенных тестовых выборках перед выбором управления u_t . Эвристическое расписание

$$u_t^* = \frac{r_t}{r_t + t\lambda g_t}, \quad \lambda > 0, \quad (25)$$

качественно воспроизводит ожидаемое поведение: при $g_t \rightarrow 0$ (старые задачи хорошо помнятся) управление стремится к единице, при $r_t \rightarrow 0$ (новая задача уже решена) к нулю, а при $\lambda g_t = r_t$ восстанавливается равномерный режим $u_t = 1/(t + 1)$. Это направление дает надежду на расписание, автоматически адаптирующееся к структуре конкретного потока задач.

Экспериментальная проверка в подразделе 4.2.6 показывает, что адаптивное

расписание (25) уступает $u_t = 1/(t + 1)$ на реальном датасете медицинских изображений. Получение теоретически обоснованной адаптивной формулы остается открытой задачей будущей работы.

3.2.7. Обсуждение

Подраздел показал, что Generative Replay естественным образом укладывается в общую постановку оптимального управления из Раздела 2. Управление $u_t \in [0, 1]$ интерпретируется как доля новых данных в обучающей выборке. Условие g принимает форму ε_t -допустимости. Функция награды задается через взвешенную среднюю ошибку модели на изученных задачах.

Получены следующие теоретические результаты. Достаточные условия допустимости управления через липшицевость потерь и через устойчивость алгоритма обучения к замене одного примера. Верхняя оценка средней ошибки для произвольного расписания u_t и обратная задача восстановления расписания по целевым весам задач с явной формулой $u_t = \alpha_{t+1}/S_{t+1}$. В квадратичном приближении получены замкнутая форма шага, спектральная оценка и безусловная оценка $\bar{\varepsilon}^* + LD^2/2$. При одинаковых гессианах и независимых оптимумах задач шаг Generative Replay сводится к экспоненциальному скользящему среднему, условия сходимости в среднем квадратичном совпадают с классическим Роббинсом-Монро. Жадный выбор порядка задач локально минимизирует безусловную оценку, а эвристическое адаптивное расписание (25) обозначено как направление дальнейшей работы.

Все теоретические результаты проверяются численно в Разделе 4.

4. Эксперименты

В этом разделе приводится экспериментальная проверка результатов работы. Подраздел 4.1 посвящен задаче прогнозирования цен и проверяет вывод подраздела 3.1 о необходимости зависимости условия g от наблюдаемой выборки. Подраздел 4.2 проверяет теорию Generative Replay из подраздела 3.2 на синтетических задачах и на реальном датасете медицинских изображений. Полные конфигурации каждого эксперимента, использованные значения гиперпараметров и ссылка на исходный код приведены в Приложении Д.3.

4.1. Деградация системы при прогнозировании цен

В этом подразделе проверяется основной вывод подраздела 3.1. Сравниваются две стратегии управления: жадная с наивным условием (10) и жадная с аккуратным условием (11). Измеряются размер активной выборки N_t как функция шага и локальная метрика R^2 модели на той же выборке.

Датасет. Используется датасет California Housing [38]. Он содержит 20 640 записей о медианной цене жилья по районам Калифорнии по данным переписи 1990 года. Каждая запись описывается восемью числовыми признаками: медианный доход домохозяйств, медианный возраст домов, среднее число комнат и спален, население района, средний размер семьи, географическая широта и долгота. Целевая переменная задается медианной стоимостью жилья в районе в сотнях тысяч долларов. Датасет удобен для постановки задачи прогнозирования цен и используется как стандартный пример в литературе по регрессии [41, 42, 43].

Схема одного шага. На каждом шаге процесса происходит одно взаимодействие модели с покупателем. Случайно выбирается индекс $i \sim U(1, N_0)$, вычисляется рекомендация $z_t = m_{\theta^t}(\mathbf{x}_i) + u_t$, и покупатель отвечает согласием с вероятностью

$$p_t \propto \exp\left[-\frac{z_t - y_i^0}{y_i^0}\right]$$

или отказом с вероятностью $1 - p_t$. Активная выборка обновляется в зависимости от ответа. Модель регрессии цен дообучается раз в τ шагов на текущей активной выборке. Схема одного шага приведена на Рис. 1.




Рис. 1: Один шаг процесса прогнозирования цен с петлей обратной связи. Активная выборка $(\mathbf{X}_t, \mathbf{y}_t)$ используется для обучения модели m_{θ^t} раз в τ шагов. Модель выдает прогноз $y' = m_{\theta^t}(\mathbf{x}^i)$ по случайно выбранному объекту $\mathbf{x}^i$. Управление u_t выбирается так, чтобы условие $g(f_t, h_{t+1}, u_t) \leq 0$ было выполнено, и формирует рекомендацию $z_t = y' + u_t$. Пользователь принимает рекомендацию с вероятностью p_t и тогда пара $(\mathbf{x}^i, z_t)$ добавляется в активную выборку, или отказывается с вероятностью $1 - p_t$ и тогда исходная пара $(\mathbf{x}^i, y_i)$ из выборки удаляется. Цикл замыкается переходом к следующему шагу $t \leftarrow t + 1$.

Параметры. Активная выборка инициализируется $N_0 = 20\,640$ записями из датасета. В качестве модели регрессии цен используется градиентный бустинг с базовыми настройками библиотеки `scikit-learn` [43]. Все векторные операции и численные вычисления выполняются средствами библиотеки NumPy [44]. Период переобучения $\tau = 30$ шагов. Для жадной стратегии с наивным условием (10) управление держится равным фиксированной надбавке. Для аккуратной стратегии с условием (11) надбавка уменьшается, если за последние шаги наблюдаемое число согласий падает или если метрика R^2 ухудшается на очередном переобучении.

Результаты. На Рис. 2 приведены кривые N_t и R^2 для трех стратегий. Нулевое управление $u_t = 0$ оставляет рекомендацию равной предсказанию модели без надбавки: размер активной выборки N_t практически не убывает, а R^2 медленно растет за счет того, что модель постепенно дообучается на собственных подтвержденных рекомендациях через петлю обратной связи. В жадной стратегии без коррекции N_t монотонно убывает к нулю, а R^2 продолжает расти. Модель формально показывает хорошее качество предсказания, но фактически учится на своих же рекомендациях, и активная выборка к концу эксперимента

становится почти пустой. В аккуратной стратегии N_t остается на стабильном уровне, R^2 растет медленнее, но система продолжает работать на всем горизонте эксперимента.




Рис. 2: Сравнение нулевого, наивной и аккуратной жадных стратегий на задаче прогнозирования цен. Слева приведен размер активной выборки N_t как функция шага. Справа приведена метрика R^2 модели по целевой переменной на той же выборке. Синие кривые отвечают нулевому управлению $u_t \equiv 0$, при котором N_t сохраняется и R^2 медленно растет за счет петли обратной связи. Красные кривые отвечают наивной жадной стратегии, которая ведет систему к деградации. Зеленые кривые отвечают аккуратной стратегии, которая сохраняет систему работоспособной.

Эксперимент подтверждает основной вывод подраздела 3.1. Условие g в постановке (3)–(5) должно учитывать наблюдаемую выборку, а не только текущее состояние модели и среды. Без такой зависимости жадная стратегия максимизирует локальную метрику и одновременно разрушает систему. С зависимостью от наблюдаемой выборки та же стратегия сохраняет рост метрики и не теряет пользователей.

4.2. Generative Replay в задаче непрерывного обучения

В этом подразделе проверяются теоретические результаты подраздела 3.2 о методе Generative Replay. Сначала описывается единый протокол обучения для всех экспериментов и расписания управления, затем приводятся пять экспериментов: на квадратичной регрессии вне класса гипотез (подраздел 4.2.2), на задаче с попарно ортогональными носителями гессиянов (подраздел 4.2.3), на жадном выборе порядка задач (подраздел 4.2.4), на линейной рекурсии с независимыми случайными оптимумами (подраздел 4.2.5) и на реальной задаче классификации медицинских изображений (подраздел 4.2.6).

4.2.1. Общий протокол обучения

Есть T задач $D_1, \dots, D_T$ с непересекающимися источниками данных. Через θ^t обозначаются веса модели m_{θ^t} , увидевшей задачи $D_1, \dots, D_t$, через G_t обозначается генератор повторения, обученный по тем же t задачам. Процесс задается последовательностью переходов

$$(\theta^t, G_t) \longrightarrow (\theta^{t+1}, G_{t+1}), \quad t = 0, 1, \dots, T - 1.$$

Один переход $\theta^t \rightarrow \theta^{t+1}$ определяется управлением $u_{t+1} \in [0, 1]$ и устроен в три шага. Формируется обучающий буфер $\mathcal{D}_{t+1}$ длины W , в котором доля u_{t+1} есть пары $(\mathbf{x}, y) \sim D_{t+1}$ из новой задачи, а доля $1 - u_{t+1}$ есть пары $(\mathbf{x}, m_{\theta^t}(\mathbf{x}))$ с $\mathbf{x} \sim G_t$. На этом буфере запускается процедура минимизации функционала из начальной точки θ^t , дающая новые веса θ^{t+1} . Генератор G_{t+1} обновляется так, чтобы в его носитель попадала задача D_{t+1} . На первом переходе генератор G_0 еще не определен, поэтому $u_1 = 1$ и буфер $\mathcal{D}_1$ целиком состоит из D_1 .

Схема одного перехода приведена на Рис. 3.




Рис. 3: Один блок процесса Generative Replay. Управление u_{t+1} задает долю новых данных в буфере $\mathcal{D}_{t+1}$: с вероятностью u_{t+1} берется пара из задачи D_{t+1} , с вероятностью $1 - u_{t+1}$ берется пара из генератора G_t с меткой от текущей модели. На буфере выполняется N шагов минимизации, дающих веса θ^{t+1} . Затем генератор обновляется до G_{t+1} .

Расписания управления. В экспериментах сравниваются три семейства расписаний u_t . Первое семейство `inv` с параметром $\alpha > 0$ задает $u_t = \alpha / (t + 1)$ при $t \geq 1$. По Утверждению 2 при $\alpha = 1$ оно дает равномерные веса задач $\alpha_s = 1/T$ в финальной модели, при $\alpha > 1$ поздние задачи получают чуть больший

вес, при $\alpha < 1$ меньший. Второе семейство **const** с параметром $u \in (0, 1)$ задает $u_t = u$ для всех $t \geq 1$. По Лемме 2 веса образуют геометрическую последовательность $\alpha_s = u(1 - u)^{T-s}$ при $s \geq 2$ и $\alpha_1 = (1 - u)^{T-1}$. Третье семейство **exp** с параметром $\alpha > 0$ задает $u_t = (e^{-\alpha t/(T-1)} - e^{-\alpha})/(1 - e^{-\alpha})$ при $t \geq 1$ и плавно убывает от $u_1 \approx 1$ до $u_{T-1} = 0$.

Графики трех семейств для нескольких значений параметра приведены на Рис. 4.




Рис. 4: Три семейства расписаний u_t как функции номера блока t при $T = 10$. Слева расписание **inv** с $\alpha \in \{0,5; 1; 1,5\}$, посередине **const** с $u \in \{0,2; 0,5; 0,8\}$, справа **exp** с $\alpha \in \{1; 2; 4\}$. Расписание **inv** быстро убывает, **const** остается постоянным, **exp** плавно убывает до $u_{T-1} = 0$.

4.2.2. Регрессия параболы линейной моделью

Что проверяется. Эксперимент проверяет монотонность средней ошибки из Теоремы 3 и предсказание Утверждения 2 о соответствии расписаний весам задач. Расписание **inv** с $\alpha = 1$ дает равномерные веса задач, **const** дает геометрически убывающие веса с упором на поздние задачи. Ожидается, что при **inv** ошибка по всем задачам выходит на уровень совместного обучения, при **const** остается выше за счет просадки ранних задач.

Конструкция задач. Парабола $y = x^2$ разбита на $T = 10$ непересекающихся участков по x . Задача D_s состоит из пар (x_i, y_i) с $x_i \sim \text{Uniform}[s, s+1]$ и $y_i = x_i^2$. В качестве модели используется линейная регрессия $\hat{y} = w_0 + w_1 x$, не способная точно воспроизвести квадратичную зависимость. Буфер $\mathcal{D}_{t+1}$ длины $W = 500$, доля новых данных $u_{t+1} = 0,5$. Стохастический градиентный спуск с шагом $\eta = 10^{-2}$, $N = 500$ итераций на блок, усреднение по пяти реализациям.

Метрики. Записываются три величины: ошибка $\mathcal{L}_t^{\text{curr}} = \mathcal{L}_t(\boldsymbol{\theta}^t)$ на текущей задаче, средняя ошибка $\mathcal{L}_t = \frac{1}{t} \sum_{s=1}^t \mathcal{L}_s(\boldsymbol{\theta}^t)$ по всем изученным задачам и совместный ориентир $\mathcal{L}_T^{\text{joint}} = \min_{\boldsymbol{\theta}} \frac{1}{T} \sum_{s=1}^T \mathcal{L}_s(\boldsymbol{\theta})$ для модели, обученной офлайн на $D_1 \cup \dots \cup D_T$.

Результаты. На Рис. 5 приведены кривые $\mathcal{L}_t^{\text{curr}}$ и $\mathcal{L}_t$ для трех расписаний. Величина $\mathcal{L}_t$ монотонно снижается с поступлением новых блоков и асимптотически подходит к $\mathcal{L}_T^{\text{joint}}$. Расписания **inv** и **exp** дают одинаковый асимптотический уровень. Расписание **const** сходится медленнее: постоянная доля повторения не учитывает накопленный объем прошлых задач.




Рис. 5: Регрессия параболы линейной моделью: $\mathcal{L}_t^{\text{curr}}$ (синяя) и $\mathcal{L}_t$ (зеленая) как функции шага обучения t для трех расписаний u_t . Черный пунктир обозначает уровень совместного обучения $\mathcal{L}_T^{\text{joint}}$. Заливка показывает стандартное отклонение по пяти реализациям.

Обсуждение. Картина согласуется с Теоремой 3: расписание с равномерными весами доставляет минимум верхней оценки средней ошибки. Геометрический вес ранних задач при **const** экспоненциально мал по $T - s$, поэтому соответствующая кривая лежит выше **inv** и не достигает уровня совместного обучения. Семейство **exp** выходит на тот же уровень, что и **inv** за счет близких к равномерным весов при выбранных параметрах. Эксперимент проверяет одновременно два теоретических предсказания: соответствие управления и весов задач из Утверждения 2 и оценку (20) монотонности по T . Разрыв $\mathcal{L}_T - \mathcal{L}_T^{\text{joint}}$ объясняется ограниченностью линейной модели на квадратичной целевой функции и составляет $\bar{\varepsilon}^*$ из спектральной теории.

4.2.3. Ортогональные носители гессианов

Что проверяется. Эксперимент проверяет Следствие 1: при попарной ортогональности носителей гессианов $\pi_t = 0$ и финальная ошибка не зависит от расписания. Конструкция SVD-задач делает условие $H_{t+1}\Sigma_t = 0$ явным: оптимум каждой задачи лежит на одной координате общего ортогонального базиса.

Конструкция задач. Случайная ортонормированная матрица $V \in \mathbb{R}^{T \times T}$ имеет столбцы $v_1, \dots, v_T$. Задача D_s задается выборкой $X_s = \sigma_s z_s v_s^\top$, $Y_s = \sigma_s z_s$, где $z_s \in \mathbb{R}^N$ есть случайный единичный вектор. Совместный оптимум $w^{\text{joint}} = \sum_s v_s$ доставляет нулевую ошибку на всех задачах. Параметры: $T = 10$, $W = 300$, $u_{t+1} = 0,5$, $\eta = 10^{-2}$, $N = 300$ итераций на блок, пять реализаций.

Результаты. На Рис. 6 приведены кривые $\mathcal{L}_t^{\text{curr}}$ и $\mathcal{L}_t$ для трех расписаний. Появление новой задачи порождает короткий всплеск $\mathcal{L}_t^{\text{curr}}$, который спадает после нескольких шагов градиентного спуска. Кривая $\mathcal{L}_t$ монотонно убывает к нулю, поскольку ортогональность направлений v_s дает $\mathcal{L}_T^{\text{joint}} = 0$.




Рис. 6: Ортогональные носители гессианов: $\mathcal{L}_t^{\text{curr}}$ (синяя) и $\mathcal{L}_t$ (зеленая) как функции шага обучения t для трех расписаний u_t . Черный пунктир обозначает $\mathcal{L}_T^{\text{joint}} = 0$. Заливка показывает стандартное отклонение по пяти реализациям.

Обсуждение. Все три расписания решают задачу примерно одинаково и выходят на $\mathcal{L}_T \rightarrow 0$, при этом *inv* устойчиво держится чуть ниже остальных по $\mathcal{L}_t^{\text{curr}}$ за счет более плавного изменения весов поздних задач. Сопоставимость траекторий подтверждает Следствие 1: при ортогональных носителях гессианов величина π_t равна нулю, и финальная ошибка не зависит от выбора расписания. Это контрольный эксперимент. Если бы кривые расписаний начали расходиться в этой постановке, это указывало бы на нарушение условия ортогональности

или на численные эффекты конечного числа шагов градиентного спуска. Ни того, ни другого в пределах пяти реализаций не наблюдается.

4.2.4. Жадный выбор порядка задач

Что проверяется. Эксперимент проверяет следующее предсказание спектральной теории. По безусловной оценке из Теоремы 5 верхняя оценка финальной ошибки зависит от перестановки задач σ только через сумму $\sum_t \|\Delta_t\|^2$, где $\Delta_t = \theta_{\sigma(t+1)}^* - \theta^t$. Жадная стратегия выбора порядка локально минимизирует эту сумму и должна доставлять меньшее $\mathcal{L}_T$ среди стратегий без знания будущих шагов. По Лемме 4 при точной внутренней минимизации финальное состояние θ^T не зависит от порядка, поэтому эффект порядка локализован в канале неточной внутренней минимизации.

Конструкция. Размерность параметра $d = 50$, число задач $T \in \{3, 4, 5, 6, 7\}$. Гессианы задаются разложением $H_s = U_s \Lambda_s U_s^\top$ со случайной ортогональной $U_s \in O(d)$ и собственными значениями $\lambda_{s,i} \sim \text{LogUnif}[1, 10]$. Оптимумы задач задаются так:

$$\theta_s^* \sim 0,1 \cdot \mathcal{N}(0, I_d) \text{ при } s \neq s^*, \quad \theta_{s^*}^* = \frac{R}{\sqrt{d}} \xi, \quad \xi \sim \mathcal{N}(0, I_d), \quad R = 20,$$

индекс выделенной задачи s^* выбирается равновероятно. Потери квадратичны: $\mathcal{L}_s(\theta) = \frac{1}{2} \|\theta - \theta_s^*\|_{H_s}^2$. На каждом переходе делается один шаг градиентного спуска с шагом $\eta_t = 0,5/\lambda_{\max}(M_t)$, что моделирует режим неточной внутренней минимизации.

Сравниваемые стратегии. Жадная стратегия $\sigma_{\text{gr}}(t+1) = \arg \min_s \|\theta_s^* - \theta^t\|$ среди оставшихся задач, случайный порядок (усреднение по 200 выборкам), антижадная стратегия $\sigma_{\text{anti}}(t+1) = \arg \max_s \|\theta_s^* - \theta^t\|$ как опорная и оптимальный порядок (полный перебор $T!$ перестановок). Для каждого значения T усреднение проводится по 30 независимым реализациям набора задач.

Результаты. На Рис. 7 приведена зависимость средней финальной ошибки $\mathcal{L}_T$ от числа задач для четырех стратегий и теоретического ориентира $\mathcal{L}_T^{\text{joint}}$ совместного обучения.




Рис. 7: Средняя финальная ошибка $\mathcal{L}_T$ как функция числа задач T для жадного, случайного, антижадного и оптимального порядков. Черный пунктир показывает теоретический ориентир совместного обучения $\mathcal{L}_T^{\text{joint}}$. Усы соответствуют стандартной ошибке среднего по 30 независимым реализациям.

Обсуждение. Жадная стратегия располагается между оптимальной и случайной, ближе к оптимальной. Расхождение со случайным порядком составляет 14–18% от $\mathcal{L}_T^{\text{random}}$, антижадная отстает на 54–171%. Разрыв с оптимальной стратегией составляет 6–8%, что заметно меньше отрыва от случайного порядка. Это подтверждает прогноз Теоремы 5: локальная минимизация $\|\Delta_t\|^2$ переносится на финальную ошибку. Эффект полностью локализован в канале неточной внутренней минимизации, что согласуется с Леммой 4: если бы внутренняя минимизация была точной, финальное состояние не зависело бы от порядка вовсе. С ростом T все стратегии сближаются с ориентиром $\mathcal{L}_T^{\text{joint}}$, поскольку увеличение числа задач уменьшает удельный вклад каждой из них в среднюю ошибку.

4.2.5. Bias-variance разложение

Что проверяется. Эксперимент проверяет точность разложения из Теоремы 6 и разделение режимов из Теоремы 7: $\sum_t u_t = \infty$ отвечает за обнуление смещения, а $u_t \rightarrow 0$ в сочетании с первым условием за обнуление дисперсии. Сравнивается эмпирическое значение $\mathbb{E}\|\theta^t - \mu^*\|^2$ с теоретической формулой.

Конструкция. Квадратичный случай Предположений 5 и 6: $H = I_d$ при $d = 20$, оптимумы $\theta_s^* \sim \mathcal{N}(0, I_d)$, $\mu^* = 0$, $\text{tr}(C^*) = 20$, $\theta^0 = (1, \dots, 1)$. Внутренняя минимизация заменяется точным решением: $\theta^{t+1} = (1 - u_t)\theta^t + u_t\theta_{t+1}^*$. Усреднение по $K = 3000$ реализациям, $T = 10^5$ блоков.

Расписания. Сравниваются пять расписаний, покрывающих три режима Теоремы 7:

- **inv** с $u_t = 1/(t + 2)$: одновременно $\sum_t u_t = \infty$ и $u_t \rightarrow 0$, ожидаемый режим $\text{bias} \rightarrow 0$, $\text{variance} \rightarrow 0$ со скоростью $\mathcal{O}(1/t)$.
- **const** с $u \in \{0,2; 0,5; 0,8\}$: $\sum_t u_t = \infty$, но $u_t \not\rightarrow 0$. Ожидаемый режим $\text{bias} \rightarrow 0$ экспоненциально, $\text{variance} \rightarrow \frac{u}{2-u}\text{tr}(C^*) \in \{2,22; 6,67; 13,33\}$.
- **quad** с $u_t = 1/(t + 2)^2$: расписание суммируемо, $\sum_t u_t < \infty$. Ожидаемый режим: bias и variance выходят на ненулевое плато.

Результаты. На Рис. 8 показаны три панели для пяти расписаний. На финальном шаге $t = T$ отношение эмпирического MSE к теоретическому остается в пределах 0,3% для всех расписаний: **inv** дает 0,992, **const** с $u \in \{0,2; 0,5; 0,8\}$ дает 1,003, 1,000, 0,999, **quad** дает 1,000. Стационарная дисперсия для **const** на сетке $u \in \{0,1; 0,3; 0,5; 0,7; 0,9\}$ совпадает с теоретической $\frac{u}{2-u}\text{tr}(C^*)$ в пределах 0,1%.

Обсуждение. Расписание **inv** обнуляет обе компоненты со скоростью $\mathcal{O}(1/t)$ и устойчиво дает наименьшее MSE среди сравниваемых стратегий. Семейство **const** обнуляет смещение экспоненциально, но удерживает дисперсию на стационарном уровне $\frac{u}{2-u}\text{tr}(C^*)$, монотонно растущем с u : большой u ускоряет забывание ранних задач ценой постоянного шума. Расписание **quad** нарушает $\sum_t u_t = \infty$ и оставляет смещение на ненулевом плато. Совпадение эмпирических кривых с теоретической формулой в пределах 0,3% при $K = 3000$ реализациях показывает, что разложение Теоремы 6 обладает достаточной точностью, чтобы служить руководящим принципом при выборе расписания в задачах с независимыми оптимумами и общим гессианом. Эксперимент явно разделяет три режима из Теоремы 7 и подтверждает эквивалентность условиям Роббинса-Монро.




Рис. 8: Bias-variance разложение в линейной рекурсии с независимыми оптимизаторами при $H = I_d$, $d = 20$, $T = 10^5$, $K = 3000$. Слева приведено $\text{bias}^2(t) = \|\mathbb{E}[\theta^t] - \mu^*\|^2$, посередине $\text{Var}(t) = \text{tr}(\text{Cov}(\theta^t))$, справа $\text{MSE}(t) = \mathbb{E}\|\theta^t - \mu^*\|^2$. Расписание `inv` обнуляет обе компоненты, семейство `const` обнуляет смещение и удерживает дисперсию на стационарном уровне $\frac{u}{2-u}\text{tr}(C^*)$, `quad` оставляет обе компоненты на ненулевом плато.

4.2.6. ChestX-Ray

Датасет. Используется датасет NIH ChestX-Ray [36]: рентгеновские снимки грудной клетки с разметкой по 14 диагнозам и классом «норма». Отобраны пять патологий (Atelectasis, Cardiomegaly, Consolidation, Edema, Effusion) как пять задач $D_1, \dots, D_5$ бинарной классификации соответствующего диагноза против остальных снимков. Класс «норма» играет роль начального состояния. Для каждой задачи берется $N = 4000$ обучающих снимков и независимая тестовая выборка.

Модель и обучение. В качестве модели используется MobileNetV2 [37] с головой, предобученной на ImageNet. Снимки размера 224×224 , оптимизатор Adam [45] с шагом $\eta = 3 \cdot 10^{-4}$ и размером минибатча 64, 25 эпох на блок, буфер длины $W = 4000$. Повторение реализуется через сохраненный буфер представительных примеров уже изученных задач с псевдо-метками, восстанавливаемыми текущей моделью.

Метрика. В качестве метрики используется AUC по каждой из шести болезней. Сводные величины: Avg6 как средний AUC по всем шести болезням, Avg5 как средний AUC по пяти патологиям без класса «норма». Верхний ориентир: совместное обучение `multiclass` без разбиения на блоки.

Сравниваемые стратегии. К трем расписаниям `inv`, `const`, `exp` добавляется адаптивная стратегия `adaptive` из (25):

$$u_t = \text{clip}\left(\frac{r_t}{r_t + \lambda g_t}, u_{\min}, u_{\max}\right),$$

где r_t есть потеря на текущей задаче, g_t есть средняя потеря на изученных задачах, $u_{\min} = 0,05$, $u_{\max} = 0,95$. Усреднение по пяти запускам с разными начальными значениями случайного генератора.

Сводное сравнение. На Рис. 9 и Рис. 10 приведено сравнение стратегий по двум метрикам. Лучший результат дает расписание `inv` с $\alpha = 1,5$: $\text{Avg6} = 0,758 \pm 0,011$, $\text{Avg5} = 0,782 \pm 0,010$. Разрыв с `multiclass` ориентиром 5,5 и 5,1 процентных пункта. Следом идут `adaptive` с $\lambda = 1$ и `const` с $u = 0,62$.




Рис. 9: Сводное сравнение стратегий u_t по метрике Avg6 (средний AUC по шести болезням). Цвет полосы кодирует семейство стратегий, серая полоска `multiclass` показывает верхний ориентир совместного обучения. Усы соответствуют стандартному отклонению по пяти независимым запускам.

Зависимость от параметра u в `const`. Финальное качество `const` имеет максимум около $u = 0,62$ (Рис. 11). При малых u модель практически не видит новые снимки, при больших u повторение не успевает защитить старые задачи.




Рис. 10: Сводное сравнение стратегий u_t по метрике Avg5 (средний AUC по пяти болезням без класса «норма»). Обозначения те же, что на Рис. 9.




Рис. 11: Расписание **const**: зависимость Avg6 и Avg5 от параметра u . Пунктир обозначает уровни Avg6 и Avg5 для **inv** с $\alpha = 1,5$.

Зависимость от параметра λ в **adaptive.** Качество **adaptive** слабо зависит от λ в диапазоне $[0,5; 1,5]$ и не превышает 0,74 по Avg6 (Рис. 12). Лучший $\lambda = 1$ остается ниже уровня **inv**.

Сравнение с совместным обучением по классам. На Рис. 13 приведено покомпонентное сравнение лучшего **inv** с совместным обучением. Наибольший




Рис. 12: Расписание **adaptive**: зависимость Avg6 и Avg5 от параметра λ . Пунктир обозначает уровни **inv** с $\alpha = 1,5$.

разрыв на Consolidation (0,080), наименьший на Edema (0,015), остальные в диапазоне 0,04–0,08.




Рис. 13: Покомпонентное сравнение AUC между **multiclass** ориентиром и лучшим расписанием **inv** с $\alpha = 1,5$. Усреднение по пяти запускам.

Динамика AUC по блокам. Рис. 14 показывает изменение AUC каждой болезни по ходу прохождения блоков для **inv** с $\alpha = 1,5$. На блоке 0 модель обучена только на классе «норма», AUC по остальным классам близок к 0,5. Каждый следующий блок повышает AUC соответствующей болезни и удерживает уже

выученные классы около достигнутого уровня без катастрофических потерь.




Рис. 14: Эволюция AUC каждой из шести болезней по блокам обучения для расписания `inv` с $\alpha = 1,5$. Заливка показывает стандартное отклонение по трем запускам.

Обсуждение. На реальном датасете теория Generative Replay воспроизводится в той же качественной картине, что и на синтетике. Расписание `inv` с $\alpha = 1,5$ устойчиво лучше остальных и уступает совместному обучению на 5,5 процентного пункта по Avg6 и на 5,1 по Avg5. Ни `const`, ни `adaptive` при переборе гиперпараметров до этого уровня не дотягиваются. Выбор расписания через равномерные веса задач (Утверждение 2) переносится с квадратичных моделей на нелинейные глубокие сети.

Динамика AUC по блокам соответствует ограниченному забыванию: после первого появления каждого класса модель удерживает AUC около достигнутого уровня, что отвечает поведению $u_t = \alpha/(t + 1)$ из Теоремы 3. Адаптивная стратегия (25) показывает потенциал, но уступает `inv`, что согласуется с выводом подраздела 3.2 о направлении будущей работы.

Заключение

В работе предложена постановка задачи оптимального управления для систем машинного обучения со скрытой петлей обратной связи. Состояние системы описывается парой (f_t, h_t) , оператор эволюции разделен на оператор обучения $\mathbf{H}_t$ и оператор реакции среды $\mathbf{P}_t$, а условие $g(f_t, h_{t+1}) \leq 0$ задает требования к сохранению петли и работоспособности системы. Постановка применена к двум прикладным сюжетам.

На задаче прогнозирования цен показано, что наивная жадная стратегия по локальной метрике приводит к оттоку пользователей и в пределе разрушает систему. Аккуратное условие g с зависимостью от наблюдаемой выборки восстанавливает работоспособный режим без потери качества предсказания.

Для метода Generative Replay в задаче непрерывного обучения получены достаточные условия допустимости управления через липшицевость потерь и через устойчивость алгоритма обучения к замене одного примера, верхняя оценка средней ошибки модели для произвольного расписания, а также обратная задача восстановления расписания по целевым весам задач с явной формулой $u_t = \alpha_{t+1}/S_{t+1}$. В квадратичном приближении функции потерь выведена замкнутая форма шага Generative Replay, спектральная оценка средней ошибки и безусловная оценка $\bar{\varepsilon}^* + LD^2/2$. При одинаковых гессианах задач и независимых случайных оптимумах получено разложение средней ошибки на компоненты смещения и дисперсии, а условия сходимости в среднем квадратичном эквивалентны классическим условиям Роббинса-Монро.

Все теоретические результаты проверены экспериментально на синтетических задачах и на реальном датасете NIH ChestX-Ray. Расписание $u_t = 1,5/(t+1)$ для последовательной классификации пяти заболеваний поверх класса «норма» уступает совместному многоклассовому обучению на 5,5 процентного пункта по средней метрике AUC.

Направления дальнейших исследований. Адаптивное расписание (25) из подраздела 3.2 в текущем виде уступает `inv` на реальном датасете. Получение теоретически обоснованной формулы u_t^* через локальную геометрию задачи остается открытой задачей. Спектральная теория получена в режиме идеального генератора $\bar{\mathcal{E}}_t = 0$. Включение в анализ конечной точности генератора и количественная оценка $\bar{\mathcal{E}}_t$ через число изученных задач позволили бы получить замкнутые оценки финальной ошибки в режиме длинного потока. Наконец,

перенос подхода на онлайн-обучение, где новая задача не имеет фиксированного носителя, а распределение признаков меняется непрерывно, представляет отдельный интерес.

Список литературы

- [1] Andrey Veprikov, Alexander Afanasyev, and Anton Khritankov. A mathematical model of the hidden feedback loop effect in machine learning systems. *Knowledge and Information Systems*, 67(12):11425–11454, 2025. doi:[10.1007/s10115-025-02560-w](https://doi.org/10.1007/s10115-025-02560-w).
- [2] Andrey S. Veprikov and Anton S. Khritankov. On the properties of the limit set of a repeated machine learning process under feature space transformations. *Artificial Intelligence and Decision Making*, (1):56–66, 2025.
- [3] Anton Khritankov and Anton Pilkevich. Existence conditions for hidden feedback loops in online recommender systems. In *Web Information Systems Engineering–WISE 2021: 22nd International Conference on Web Information Systems Engineering, WISE 2021, Melbourne, VIC, Australia, October 26–29, 2021, Proceedings, Part II 22*, pages 267–274. Springer, 2021. doi:[10.1007/978-3-030-91560-5_19](https://doi.org/10.1007/978-3-030-91560-5_19).
- [4] Anton Khritankov. Positive feedback loops lead to concept drift in machine learning systems. *Applied Intelligence*, 53(19):22648–22666, 2023. doi:[10.1007/s10489-023-04615-3](https://doi.org/10.1007/s10489-023-04615-3).
- [5] Ayan Sinha, David F Gleich, and Karthik Ramani. Deconvolving feedback loops in recommender systems. *Advances in neural information processing systems*, 29, 2016.
- [6] Ray Jiang, Silvia Chiappa, Tor Lattimore, András György, and Pushmeet Kohli. Degenerate feedback loops in recommender systems. In *Proceedings of the 2019 AAAI/ACM Conference on AI, Ethics, and Society*, pages 383–390, 2019.
- [7] Danielle Ensign, Sorelle A Friedler, Scott Neville, Carlos Scheidegger, and Suresh Venkatasubramanian. Runaway feedback loops in predictive policing. In *Conference on fairness, accountability and transparency*, pages 160–171. PMLR, 2018.
- [8] Anton Khritankov. Hidden feedback loops in machine learning systems: A simulation model and preliminary results. In *Software Quality: Future Perspectives on Software Engineering Quality: 13th International Conference*,

- SWQD 2021, Vienna, Austria, January 19–21, 2021, Proceedings 13*, pages 54–65. Springer, 2021. doi:[10.1007/978-3-030-65854-0_5](https://doi.org/10.1007/978-3-030-65854-0_5).
- [9] George Alexandru Adam, Chun-Hao Kingsley Chang, Benjamin Haibe-Kains, and Anna Goldenberg. Hidden risks of machine learning applied to healthcare: unintended feedback loops between models and future data causing model degradation. In *Machine Learning for Healthcare Conference*, pages 710–731. PMLR, 2020.
 - [10] George Alexandru Adam, Chun-Hao Kingsley Chang, Benjamin Haibe-Kains, and Anna Goldenberg. Error amplification when updating deployed machine learning models. In *Machine Learning for Healthcare Conference*, pages 715–740. PMLR, 2022.
 - [11] Huw C Davies. Redefining filter bubbles as (escapable) socio-technical recursion. *Sociological Research Online*, 23(3):637–654, 2018. doi:[10.1177/1360780418763824](https://doi.org/10.1177/1360780418763824).
 - [12] Dominic Spohr. Fake news and ideological polarization: Filter bubbles and selective exposure on social media. *Business Information Review*, 34(3):150–160, 2017. doi:[10.1177/0266382117722446](https://doi.org/10.1177/0266382117722446).
 - [13] Lien Michiels, Jens Leysen, Annelien Smets, and Bart Goethals. What are filter bubbles really? a review of the conceptual and empirical work. In *Adjunct Proceedings of the 30th ACM Conference on User Modeling, Adaptation and Personalization*, pages 274–279, 2022. doi:[10.1145/3511047.3538028](https://doi.org/10.1145/3511047.3538028).
 - [14] А. С. Веприков, А. П. Афанасьев, and А. С. Хританков. Математическая модель эффекта обратной связи в системах искусственного интеллекта. In *Математические методы распознавания образов: Тезисы докладов 21-й Всероссийской конференции с международным участием, г. Москва*, volume 12, pages 35–37, Москва, 2023. Российская академия наук.
 - [15] Hanul Shin, Jung Kwon Lee, Jaehong Kim, and Jiwon Kim. Continual learning with deep generative replay. In *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4–9, 2017, Long Beach, CA, USA*, pages 2990–

- 2999, 2017. URL <https://proceedings.neurips.cc/paper/2017/hash/0efbe98067c6c73dba1250d2beaa81f9-Abstract.html>.
- [16] German I. Parisi, Ronald Kemker, Jose L. Part, Christopher Kanan, and Stefan Wermter. Continual lifelong learning with neural networks: A review. *Neural Networks*, 113:54–71, 2019. doi:[10.1016/j.neunet.2019.01.012](https://doi.org/10.1016/j.neunet.2019.01.012).
 - [17] Raia Hadsell, Dushyant Rao, Andrei A. Rusu, and Razvan Pascanu. Embracing change: Continual learning in deep neural networks. *Trends in Cognitive Sciences*, 24(12):1028–1040, 2020. doi:[10.1016/j.tics.2020.09.004](https://doi.org/10.1016/j.tics.2020.09.004).
 - [18] D. Sculley, Gary Holt, Daniel Golovin, Eugene Davydov, Todd Phillips, Dietmar Ebner, Vinay Chaudhary, Michael Young, Jean-François Crespo, and Dan Dennison. Hidden technical debt in machine learning systems. In *Advances in Neural Information Processing Systems*, volume 28, 2015.
 - [19] Herbert Robbins and Sutton Monro. A stochastic approximation method. *The Annals of Mathematical Statistics*, pages 400–407, 1951.
 - [20] Rohan Taori and Tatsunori Hashimoto. Data feedback loops: Model-driven amplification of dataset biases. In *International Conference on Machine Learning*, pages 33883–33920. PMLR, 2023.
 - [21] Alexandra Chouldechova and Aaron Roth. A snapshot of the frontiers of fairness in machine learning. *Communications of the ACM*, 63(5):82–89, 2020. doi:[10.1145/3376898](https://doi.org/10.1145/3376898).
 - [22] CAIS. Statement on ai risk. <https://www.safe.ai/statement-on-ai-risk>, 2023.
 - [23] Harini Suresh, Natalie Lao, and Ilaria Liccardi. Misplaced trust: Measuring the interference of machine learning in human decision-making. In *Proceedings of the 12th ACM Conference on Web Science*, pages 315–324, 2020. doi:[10.1145/3394231.3397922](https://doi.org/10.1145/3394231.3397922).
 - [24] Bo Li, Peng Qi, Bo Liu, Shuai Di, Jingen Liu, Jiquan Pei, Jinfeng Yi, and Bowen Zhou. Trustworthy ai: From principles to practices. *ACM Computing Surveys*, 55(9):1–46, 2023. doi:[10.1145/3555803](https://doi.org/10.1145/3555803).

- [25] Lu Cheng, Kush R Varshney, and Huan Liu. Socially responsible ai algorithms: Issues, purposes, and challenges. *Journal of Artificial Intelligence Research*, 71: 1137–1181, 2021. doi:[10.1613/jair.1.12814](https://doi.org/10.1613/jair.1.12814).
- [26] Joseph Sifakis and David Harel. Trustworthy autonomous system development. *ACM Transactions on Embedded Computing Systems*, 22(3):1–24, 2023. doi:[10.1145/3545178](https://doi.org/10.1145/3545178).
- [27] Б. Р. Андриевский, М. В. Балашов, Н. Н. Бахтадзе, А. А. Галяев, В. М. Глумов, М. В. Губко, Ю. П. Емельянова, Н. Н. Карабутов, Н. А. Коргин, Ю. И. Кудинов, et al. *Теория управления (дополнительные главы)*. ООО «Ленанд», 2019.
- [28] С. В. Емельянов, А. В. Ильин, С. К. Коровин, В. В. Фомичев, and А. С. Фурсов. *Математические методы теории управления. Проблемы устойчивости, управляемости и наблюдаемости*. Физматлит, М., 2014.
- [29] Oded Galor. *Discrete Dynamical Systems*. Springer Science & Business Media, 2007. doi:[10.1007/3-540-36776-4](https://doi.org/10.1007/3-540-36776-4).
- [30] James T Sandefur. *Discrete Dynamical Systems: Theory and Applications*. Clarendon Press, 1990.
- [31] Anthony Robins. Catastrophic forgetting, rehearsal and pseudorehearsal. *Connection Science*, 7(2):123–146, 1995. doi:[10.1080/09540099550039318](https://doi.org/10.1080/09540099550039318).
- [32] Sylvestre-Alvise Rebuffi, Alexander Kolesnikov, Georg Sperl, and Christoph H. Lampert. icarl: Incremental classifier and representation learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 2001–2010, 2017.
- [33] David Lopez-Paz and Marc’Aurelio Ranzato. Gradient episodic memory for continual learning. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [34] Renhao Wang, Kevin Frans, Pieter Abbeel, Sergey Levine, and Alexei A. Efros. Prioritized generative replay, 2025. URL <https://arxiv.org/abs/2410.18082>.

- [35] William Yue, Bo Liu, and Peter Stone. t-dgr: A trajectory-based deep generative replay method for continual learning in decision making. In *Conference on Lifelong Learning Agents*, Proceedings of Machine Learning Research, pages 481–497. PMLR, 2024. URL <https://proceedings.mlr.press/v274/yue25a.html>.
- [36] Xiaosong Wang, Yifan Peng, Le Lu, Zhiyong Lu, Mohammadhadi Bagheri, and Ronald M Summers. Chestx-ray8: Hospital-scale chest x-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 2097–2106, 2017.
- [37] Mark Sandler, Andrew Howard, Menglong Zhu, Andrey Zhmoginov, and Liang-Chieh Chen. Mobilenetv2: Inverted residuals and linear bottlenecks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 4510–4520, 2018.
- [38] R. Kelley Pace and Ronald Barry. Sparse spatial autoregressions. *Statistics & Probability Letters*, 33(3):291–297, 1997.
- [39] Olivier Bousquet and André Elisseeff. Stability and generalization. *Journal of Machine Learning Research*, 2:499–526, 2002.
- [40] Moritz Hardt, Benjamin Recht, and Yoram Singer. Train faster, generalize better: Stability of stochastic gradient descent. In *International Conference on Machine Learning*, pages 1225–1234. PMLR, 2016.
- [41] Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. O’Reilly Media, Sebastopol, CA, 2 edition, 2019.
- [42] Christoph Molnar. *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*. Independently published, 2 edition, 2022. URL <https://christophm.github.io/interpretable-ml-book/>.
- [43] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos,

- D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [44] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, Ralf Gommers, Pauli Virtanen, David Cournapeau, Eric Wieser, Julian Taylor, Sebastian Berg, Nathaniel J. Smith, Robert Kern, Matti Picus, Stephan Hoyer, Marten H. van Kerkwijk, Matthew Brett, Allan Haldane, Jaime Fernández del Río, Mark Wiebe, Pearu Peterson, Pierre Gérard-Marchant, Kevin Sheppard, Tyler Reddy, Warren Weckesser, Hameer Abbasi, Christoph Gohlke, and Travis E. Oliphant. Array programming with NumPy. *Nature*, 585(7825):357–362, 2020. doi:[10.1038/s41586-020-2649-2](https://doi.org/10.1038/s41586-020-2649-2).
- [45] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.

Приложение А. Непустота множества допустимых управлений

В этом приложении приведено полное доказательство Утверждения 1 из подраздела 2 о непустоте множества допустимых управлений на каждом шаге.

А.1. Доказательство Утверждения 1

Применим индукцию по t . На нулевом шаге по Предположению 1 верно $g(f_0, h_0) \leq 0$. При $u_0 = 0$ из первого условия утверждения следует $h_1 = h_0$, поэтому $g(f_0, h_1) = g(f_0, h_0) \leq 0$, и управление допустимо. Шаг индукции. Пусть $g(f_t, h_t) \leq 0$. При $u_t = 0$ снова $h_{t+1} = h_t$, откуда $g(f_t, h_{t+1}) = g(f_t, h_t) \leq 0$. Состояние следующего шага есть $f_{t+1} = \mathbf{P}_t(f_t, h_{t+1})$, и по второму условию утверждения $g(f_{t+1}, h_t) \leq 0$. Из $h_{t+1} = h_t$ получаем $g(f_{t+1}, h_{t+1}) \leq 0$, что и требовалось. $\square$

Приложение Б. Достаточные условия допустимости управления

В этом приложении приведены полные доказательства результатов из подраздела 3.2 о достаточных условиях допустимости управления.

Б.1. Доказательство Теоремы 1

Требуется показать, что при $u_t \in (0, 1)$ из условий

$$\mathcal{L}_{t+1}(\boldsymbol{\theta}^{t+1}) \leq \frac{\varepsilon_t}{2u_t}, \quad d(\boldsymbol{\theta}^{t+1}, \boldsymbol{\theta}^t) \leq \frac{\varepsilon_t}{2(1-u_t)L_{\text{loss}}}$$

следует неравенство $\mathcal{L}_t^*(u_t) \leq \varepsilon_t$, то есть ε_t -допустимость управления.

Шаг 1. Структура обучающего функционала. По определению Generative Replay

$$\mathcal{L}_t^*(u_t) = \min_{\boldsymbol{\theta}} [u_t \mathcal{L}_{t+1}(\boldsymbol{\theta}) + (1-u_t)R_t(\boldsymbol{\theta})],$$

где $R_t(\boldsymbol{\theta}) = \mathbb{E}_{\mathbf{x} \sim G_t} [\mathcal{L}(m_{\boldsymbol{\theta}}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x}))]$ обозначает функционал повторения с самодистилляцией. Подставляя $\boldsymbol{\theta} = \boldsymbol{\theta}^{t+1}$ из условия теоремы, получаем верхнюю оценку

$$\mathcal{L}_t^*(u_t) \leq u_t \mathcal{L}_{t+1}(\boldsymbol{\theta}^{t+1}) + (1-u_t)R_t(\boldsymbol{\theta}^{t+1}).$$

Шаг 2. Оценка слагаемого повторения через Lipschitz. Будем считать, что функция потерь является функцией расхождения, $\mathcal{L}(z, z) = 0$ для всех z . Это свойство выполнено для среднеквадратичной потери, кросс-энтропии и расстояния Кульбака-Лейблера. По Предположению 2, применяя разностную оценку к парам $(\boldsymbol{\theta}^{t+1}, m_{\boldsymbol{\theta}^t}(\mathbf{x}))$ и $(\boldsymbol{\theta}^t, m_{\boldsymbol{\theta}^t}(\mathbf{x}))$ и учитывая $\mathcal{L}(m_{\boldsymbol{\theta}^t}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x})) = 0$, получаем

$$\mathcal{L}(m_{\boldsymbol{\theta}^{t+1}}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x})) \leq L_{\text{loss}} \cdot d(\boldsymbol{\theta}^{t+1}, \boldsymbol{\theta}^t).$$

Усредняя по $\mathbf{x} \sim G_t$, получаем

$$R_t(\boldsymbol{\theta}^{t+1}) \leq L_{\text{loss}} \cdot d(\boldsymbol{\theta}^{t+1}, \boldsymbol{\theta}^t).$$

Шаг 3. Сборка. Подставляя обе оценки из условия теоремы:

$$\mathcal{L}_t^*(u_t) \leq u_t \cdot \frac{\varepsilon_t}{2u_t} + (1-u_t) \cdot L_{\text{loss}} \cdot \frac{\varepsilon_t}{2(1-u_t)L_{\text{loss}}} = \frac{\varepsilon_t}{2} + \frac{\varepsilon_t}{2} = \varepsilon_t.$$

Управление u_t удовлетворяет условию ε_t -допустимости. $\square$

Б.2. Доказательство Леммы 1

Построим цепочку выборок $S = S^{(0)}, S^{(1)}, \dots, S^{(k)} = S'$, в которой соседние выборки $S^{(i-1)}$ и $S^{(i)}$ отличаются ровно в одной позиции. Такая цепочка существует, поскольку S и S' отличаются не более чем в k позициях, и различающиеся элементы можно заменять последовательно по одному.

По Определению 1 для каждой пары соседних выборок

$$\sup_z |\mathcal{L}(\mathbf{H}_t(S^{(i-1)}), z) - \mathcal{L}(\mathbf{H}_t(S^{(i)}), z)| \leq \beta_m.$$

По неравенству треугольника, накопленному вдоль цепочки длины k ,

$$\sup_z |\mathcal{L}(\mathbf{H}_t(S), z) - \mathcal{L}(\mathbf{H}_t(S'), z)| \leq \sum_{i=1}^k \beta_m = k\beta_m.$$

$\square$

Б.3. Доказательство Теоремы 2

Шаг 1. Стартовая точка. Обозначим выборку, отвечающую управлению u , через $S(u)$: um объектов новой задачи D_{t+1} и $(1-u)t$ объектов выборки повторения $\tilde{D}_t$. Внутренняя оптимизация выдает веса $\boldsymbol{\theta}^{t+1}(u) = \mathbf{H}_t(S(u))$. Считаем $\mathcal{L}(z, z) = 0$, как в Шаге 2 доказательства Теоремы 1.

При $u = 0$ по условию $\boldsymbol{\theta}^{t+1}(0) = \boldsymbol{\theta}^t$. Метки в $\tilde{D}_t$ порождены текущей моделью $m_{\boldsymbol{\theta}^t}$ через самодистилляцию, поэтому на этих объектах

$$\mathcal{L}(\boldsymbol{\theta}^{t+1}(0), \tilde{D}_t) = \mathbb{E}_{\mathbf{x} \sim G_t} \mathcal{L}(m_{\boldsymbol{\theta}^t}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x})) = 0.$$

Шаг 2. Сравнение через устойчивость. Выборки $S(u_t)$ и $S(0)$ отличаются не более чем в $k_t = u_t m$ позициях: ровно тех, где объекты из $\tilde{D}_t$ заменены на объекты новой задачи. По Лемме 1 и стабильности β_m :

$$\mathcal{L}(\boldsymbol{\theta}^{t+1}(u_t), \tilde{D}_t) \leq \mathcal{L}(\boldsymbol{\theta}^{t+1}(0), \tilde{D}_t) + u_t m \beta_m = u_t m \beta_m.$$

Шаг 3. Сборка. По определению обучающего функционала и условиям теоремы:

$$\mathcal{L}_t^*(u_t) \leq u_t \mathcal{L}_{t+1}(\boldsymbol{\theta}^{t+1}(u_t)) + (1 - u_t) \mathcal{L}(\boldsymbol{\theta}^{t+1}(u_t), \tilde{D}_t) \leq u_t \cdot \frac{\varepsilon_t}{2u_t} + (1 - u_t) \cdot u_t m \beta_m.$$

Подставляя $u_t m \beta_m \leq \varepsilon_t / (2(1 - u_t))$:

$$\mathcal{L}_t^*(u_t) \leq \frac{\varepsilon_t}{2} + (1 - u_t) \cdot \frac{\varepsilon_t}{2(1 - u_t)} = \varepsilon_t.$$

□

Приложение В. Верхняя оценка средней ошибки и обратная задача

В этом приложении приведены полные доказательства результатов из подраздела 3.2 о верхней оценке средней ошибки модели и об обратной задаче восстановления расписания.

В.1. Доказательство Леммы 2

Шаг 1. Неотрицательность. Каждое $w_{s,t+1}$ есть произведение неотрицательных множителей: $u_{s-1} \geq 0$ и $(1 - u_r) \geq 0$ при $u_r \in [0, 1]$. Все веса неотрицательны.

Шаг 2. Тождество $u_{s-1}p_s = p_s - p_{s-1}$. Положим $p_s = \prod_{r=s}^t (1 - u_r)$ при $s \leq t$ и $p_{t+1} = 1$. Имеем

$$p_{s-1} = (1 - u_{s-1})p_s = p_s - u_{s-1}p_s,$$

откуда $u_{s-1}p_s = p_s - p_{s-1}$.

Шаг 3. Телескопическое суммирование. По определению весов $w_{1,t+1} = p_1$, а $w_{s,t+1} = u_{s-1}p_s = p_s - p_{s-1}$ при $s \geq 2$. Тогда

$$\sum_{s=1}^{t+1} w_{s,t+1} = p_1 + \sum_{s=2}^{t+1} (p_s - p_{s-1}) = p_1 + (p_{t+1} - p_1) = p_{t+1} = 1.$$

□

В.2. Доказательство Леммы 3

Шаг 1. Неравенство треугольника на одном объекте. По Предположению 3 для любых θ^{t+1}, θ^t и любого объекта $(\mathbf{x}, y)$

$$\mathcal{L}(m_{\theta^{t+1}}(\mathbf{x}), y) \leq \mathcal{L}(m_{\theta^{t+1}}(\mathbf{x}), m_{\theta^t}(\mathbf{x})) + \mathcal{L}(m_{\theta^t}(\mathbf{x}), y).$$

Беря математическое ожидание по $(\mathbf{x}, y) \sim D_s$,

$$\mathcal{L}_s(\theta^{t+1}) \leq \mathbb{E}_{\mathbf{x} \sim p_s} [\mathcal{L}(m_{\theta^{t+1}}(\mathbf{x}), m_{\theta^t}(\mathbf{x}))] + \mathcal{L}_s(\theta^t). \quad (26)$$

Шаг 2. Замена истинной плотности признаков на генератор. Первое слагаемое в (26) зависит от $\mathbf{x}$ только через распределение признаков задачи D_s .

Запишем его как интеграл и добавим и вычтем плотность генератора p_{G_t} :

$$\begin{aligned} \int \mathcal{L}(m_{\boldsymbol{\theta}^{t+1}}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x})) p_s(\mathbf{x}) d\mathbf{x} &= \int \mathcal{L}(m_{\boldsymbol{\theta}^{t+1}}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x})) p_{G_t}(\mathbf{x}) d\mathbf{x} \\ &+ \int \mathcal{L}(m_{\boldsymbol{\theta}^{t+1}}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x})) (p_s(\mathbf{x}) - p_{G_t}(\mathbf{x})) d\mathbf{x}. \end{aligned}$$

Первый интеграл равен $\mathbb{E}_{\mathbf{x} \sim G_t}[\mathcal{L}(m_{\boldsymbol{\theta}^{t+1}}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x}))]$.

Шаг 3. Оценка второго интеграла. Как и в Шаге 2 доказательства Теоремы 1, считаем $\mathcal{L}(z, z) = 0$. По Предположению 2 с учетом $\mathcal{L}(m_{\boldsymbol{\theta}^t}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x})) = 0$ для всех $\mathbf{x}$ выполнено

$$\mathcal{L}(m_{\boldsymbol{\theta}^{t+1}}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x})) \leq L_{\text{loss}} \cdot d(\boldsymbol{\theta}^{t+1}, \boldsymbol{\theta}^t).$$

Обозначим $\Delta p(\mathbf{x}) = p_s(\mathbf{x}) - p_{G_t}(\mathbf{x})$. По неравенству $|\int f \Delta p| \leq \sup |f| \cdot \int |\Delta p|$ и оценке Шага 3 получаем

$$\begin{aligned} \left| \int \mathcal{L}(m_{\boldsymbol{\theta}^{t+1}}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x})) \Delta p(\mathbf{x}) d\mathbf{x} \right| &\leq L_{\text{loss}} \cdot d(\boldsymbol{\theta}^{t+1}, \boldsymbol{\theta}^t) \cdot \int |\Delta p(\mathbf{x})| d\mathbf{x} \\ &= \mathcal{E}_{\text{gen}}(s, t). \end{aligned}$$

Шаг 4. Сборка. Объединяя три шага:

$$\mathcal{L}_s(\boldsymbol{\theta}^{t+1}) \leq \mathbb{E}_{\mathbf{x} \sim G_t}[\mathcal{L}(m_{\boldsymbol{\theta}^{t+1}}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x}))] + \mathcal{L}_s(\boldsymbol{\theta}^t) + \mathcal{E}_{\text{gen}}(s, t).$$

□

В.3. Доказательство Теоремы 3

Обозначим через $\mathcal{L}_{t+1}^{(w)} = \sum_{s=1}^{t+1} w_{s,t+1} \mathcal{L}_s(\boldsymbol{\theta}^{t+1})$ взвешенную среднюю ошибку модели после шага t , через $R_t(\boldsymbol{\theta}) = \mathbb{E}_{\mathbf{x} \sim G_t}[\mathcal{L}(m_{\boldsymbol{\theta}}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x}))]$ функционал повторения. Обучающий функционал из определения GR имеет вид

$$\mathcal{L}_t^*(u_t) = u_t \mathcal{L}_{t+1}(\boldsymbol{\theta}^{t+1}) + (1 - u_t) R_t(\boldsymbol{\theta}^{t+1}), \quad (27)$$

а по условию ε_t -допустимости $\mathcal{L}_t^*(u_t) \leq \varepsilon_t$. Агрегированная ошибка генератора определяется как $\bar{\mathcal{E}}_t = L_{\text{loss}} d(\boldsymbol{\theta}^{t+1}, \boldsymbol{\theta}^t) \sum_{s=1}^t w_{s,t} \mathcal{E}_{\text{gen}}(s, t)$.

Шаг 1. Расщепление весов. Из Определения 2 напрямую следует

$$\begin{aligned} w_{1,t+1} &= \prod_{r=1}^t (1 - u_r) = (1 - u_t) w_{1,t}, \\ w_{s,t+1} &= u_{s-1} \prod_{r=s}^t (1 - u_r) = (1 - u_t) w_{s,t}, \quad 2 \leq s \leq t, \\ w_{t+1,t+1} &= u_t. \end{aligned}$$

Подставляя в определение $\mathcal{L}_{t+1}^{(w)}$, получаем

$$\mathcal{L}_{t+1}^{(w)} = (1 - u_t) \sum_{s=1}^t w_{s,t} \mathcal{L}_s(\boldsymbol{\theta}^{t+1}) + u_t \mathcal{L}_{t+1}(\boldsymbol{\theta}^{t+1}). \quad (28)$$

Шаг 2. Применение Леммы 3 к каждой задаче. Для каждого $s \leq t$ Лемма 3 дает

$$\mathcal{L}_s(\boldsymbol{\theta}^{t+1}) \leq R_t(\boldsymbol{\theta}^{t+1}) + \mathcal{L}_s(\boldsymbol{\theta}^t) + L_{\text{loss}} d(\boldsymbol{\theta}^{t+1}, \boldsymbol{\theta}^t) \mathcal{E}_{\text{gen}}(s, t),$$

где $R_t(\boldsymbol{\theta}^{t+1}) = \mathbb{E}_{\mathbf{x} \sim G_t} [\mathcal{L}(m_{\boldsymbol{\theta}^{t+1}}(\mathbf{x}), m_{\boldsymbol{\theta}^t}(\mathbf{x}))]$ и множитель $L_{\text{loss}} d(\boldsymbol{\theta}^{t+1}, \boldsymbol{\theta}^t)$ не зависят от s . Усредняя с весами $w_{s,t}$ и пользуясь $\sum_{s=1}^t w_{s,t} = 1$ (Лемма 2):

$$\sum_{s=1}^t w_{s,t} \mathcal{L}_s(\boldsymbol{\theta}^{t+1}) \leq R_t(\boldsymbol{\theta}^{t+1}) + \mathcal{L}_t^{(w)} + \bar{\mathcal{E}}_t, \quad (29)$$

где $\mathcal{L}_t^{(w)} = \sum_s w_{s,t} \mathcal{L}_s(\boldsymbol{\theta}^t)$ обозначает взвешенную среднюю ошибку на прошлом шаге.

Шаг 3. Сборка рекуррентной оценки. Подставляя (29) в (28):

$$\begin{aligned} \mathcal{L}_{t+1}^{(w)} &\leq (1 - u_t) [R_t(\boldsymbol{\theta}^{t+1}) + \mathcal{L}_t^{(w)} + \bar{\mathcal{E}}_t] + u_t \mathcal{L}_{t+1}(\boldsymbol{\theta}^{t+1}) \\ &= [u_t \mathcal{L}_{t+1}(\boldsymbol{\theta}^{t+1}) + (1 - u_t) R_t(\boldsymbol{\theta}^{t+1})] + (1 - u_t) \mathcal{L}_t^{(w)} + (1 - u_t) \bar{\mathcal{E}}_t \\ &= \mathcal{L}_t^*(u_t) + (1 - u_t) \mathcal{L}_t^{(w)} + (1 - u_t) \bar{\mathcal{E}}_t. \end{aligned}$$

По условию $\mathcal{L}_t^*(u_t) \leq \varepsilon_t$, а $(1 - u_t) \bar{\mathcal{E}}_t \leq \bar{\mathcal{E}}_t$ при $\bar{\mathcal{E}}_t \geq 0$. Получаем

$$\mathcal{L}_{t+1}^{(w)} \leq \varepsilon_t + (1 - u_t) \mathcal{L}_t^{(w)} + \bar{\mathcal{E}}_t.$$

Шаг 4. Разворачивание рекурсии. Пусть $a_t = \mathcal{L}_t^{(w)}$, $b_t = \varepsilon_t + \bar{\mathcal{E}}_t$. Имеем рекурсию $a_{t+1} \leq b_t + (1 - u_t)a_t$ с $a_0 = 0$. Индукция по t дает

$$a_{t+1} \leq \sum_{j=0}^t \left(\prod_{r=j+1}^t (1 - u_r) \right) b_j.$$

Раскрывая $b_j = \varepsilon_j + \bar{\mathcal{E}}_j$ и учитывая $\bar{\mathcal{E}}_0 = 0$ (на первом шаге задач для повторения нет),

$$\mathcal{L}_{t+1}^{(w)} \leq \sum_{j=0}^t \left(\prod_{r=j+1}^t (1 - u_r) \right) \varepsilon_j + \sum_{j=1}^t \left(\prod_{r=j+1}^t (1 - u_r) \right) \bar{\mathcal{E}}_j.$$

□

В.4. Доказательство Утверждения 2

Требуется показать, что управления $u_t = \alpha_{t+1}/S_{t+1}$ порождают веса $w_{s,T} = \alpha_s$ для всех s .

Шаг 1. Стартовое значение. При $t = 0$ имеем $u_0 = \alpha_1/S_1 = 1$, так как $S_1 = \alpha_1$.

Шаг 2. Связь $1 - u_t$ и частичных сумм. При $t \geq 1$ из определения $u_t = \alpha_{t+1}/S_{t+1}$ и $S_{t+1} = S_t + \alpha_{t+1}$:

$$1 - u_t = \frac{S_{t+1} - \alpha_{t+1}}{S_{t+1}} = \frac{S_t}{S_{t+1}}.$$

Тогда

$$\prod_{r=s}^{T-1} (1 - u_r) = \prod_{r=s}^{T-1} \frac{S_r}{S_{r+1}} = \frac{S_s \cdot S_{s+1} \cdots S_{T-1}}{S_{s+1} \cdot S_{s+2} \cdots S_T} = \frac{S_s}{S_T} = S_s,$$

поскольку $S_T = \sum_{s=1}^T \alpha_s = 1$.

Шаг 3. Подстановка в определение весов. Для $s \geq 2$:

$$w_{s,T} = u_{s-1} \prod_{r=s}^{T-1} (1 - u_r) = \frac{\alpha_s}{S_s} \cdot S_s = \alpha_s.$$

Для $s = 1$ произведение начинается с $r = 1$, поэтому значение $u_0 = 1$ в нем не участвует:

$$w_{1,T} = \prod_{r=1}^{T-1} (1 - u_r) = S_1 = \alpha_1.$$

□

Приложение Г. Спектральная теория ошибки в квадратичном приближении

В этом приложении приведены полные доказательства результатов из подраздела 3.2 о замкнутой форме шага Generative Replay, спектральной оценке средней ошибки, условии нулевого конфликта и безусловной оценке $\bar{\varepsilon}^* + LD^2/2$.

Г.1. Доказательство Леммы 4

В условиях Предположения 4 обучающий функционал имеет вид

$$\mathcal{L}_{\text{train}}(\boldsymbol{\theta}) = u_t \left[\varepsilon_{t+1}^* + \frac{1}{2}(\boldsymbol{\theta} - \boldsymbol{\theta}_{t+1}^*)^\top H_{t+1}(\boldsymbol{\theta} - \boldsymbol{\theta}_{t+1}^*) \right] + (1 - u_t) \cdot \frac{1}{2}(\boldsymbol{\theta} - \boldsymbol{\theta}^t)^\top \Sigma_t(\boldsymbol{\theta} - \boldsymbol{\theta}^t). \quad (30)$$

Это сумма двух квадратичных форм с центрами $\boldsymbol{\theta}_{t+1}^*$ и $\boldsymbol{\theta}^t$ и положительно полуопределенными матрицами H_{t+1} и Σ_t .

Шаг 1. Градиент. Дифференцируя (30) по $\boldsymbol{\theta}$:

$$\nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{train}}(\boldsymbol{\theta}) = u_t H_{t+1}(\boldsymbol{\theta} - \boldsymbol{\theta}_{t+1}^*) + (1 - u_t) \Sigma_t(\boldsymbol{\theta} - \boldsymbol{\theta}^t).$$

Собирая по $\boldsymbol{\theta}$:

$$\nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{train}}(\boldsymbol{\theta}) = M_t \boldsymbol{\theta} - b_t,$$

где $M_t = u_t H_{t+1} + (1 - u_t) \Sigma_t$ и $b_t = u_t H_{t+1} \boldsymbol{\theta}_{t+1}^* + (1 - u_t) \Sigma_t \boldsymbol{\theta}^t$.

Шаг 2. Условие минимума. Матрица M_t положительно полуопределена как линейная комбинация положительно полуопределенных H_{t+1} и Σ_t с неотрицательными коэффициентами. При положительно определенном гессиане H_{t+1} и $u_t > 0$ матрица M_t обратима. Точка минимума находится из $\nabla \mathcal{L}_{\text{train}} = 0$:

$$\boldsymbol{\theta}^{t+1} = M_t^{-1} b_t = M_t^{-1} [u_t H_{t+1} \boldsymbol{\theta}_{t+1}^* + (1 - u_t) \Sigma_t \boldsymbol{\theta}^t].$$

□

Г.2. Доказательство Леммы 5

Введем сокращения $A = H_{t+1}$, $S = \Sigma_t$, $\Delta_t = \boldsymbol{\theta}_{t+1}^* - \boldsymbol{\theta}^t$. По Лемме 4 в квадратичном приближении

$$\boldsymbol{\theta}^{t+1} = M_t^{-1} [u_t A \boldsymbol{\theta}_{t+1}^* + (1 - u_t) S \boldsymbol{\theta}^t], \quad M_t = u_t A + (1 - u_t) S. \quad (31)$$

Шаг 1. Подстановка расписания $u_t = 1/(t+1)$. В этом случае $1 - u_t = t/(t+1)$, поэтому

$$M_t = \frac{1}{t+1} (A + tS), \quad K := A + tS, \quad \boldsymbol{\theta}^{t+1} = K^{-1} (A \boldsymbol{\theta}_{t+1}^* + tS \boldsymbol{\theta}^t).$$

Шаг 2. Отклонения $\boldsymbol{\theta}^{t+1}$ от точек $\boldsymbol{\theta}_{t+1}^*$ и $\boldsymbol{\theta}^t$. Прямой подсчет:

$$\begin{aligned} \boldsymbol{\theta}^{t+1} - \boldsymbol{\theta}_{t+1}^* &= K^{-1} (A \boldsymbol{\theta}_{t+1}^* + tS \boldsymbol{\theta}^t - K \boldsymbol{\theta}_{t+1}^*) = K^{-1} \cdot tS (\boldsymbol{\theta}^t - \boldsymbol{\theta}_{t+1}^*) = -tK^{-1} S \Delta_t, \\ \boldsymbol{\theta}^{t+1} - \boldsymbol{\theta}^t &= K^{-1} (A \boldsymbol{\theta}_{t+1}^* + tS \boldsymbol{\theta}^t - K \boldsymbol{\theta}^t) = K^{-1} A (\boldsymbol{\theta}_{t+1}^* - \boldsymbol{\theta}^t) = K^{-1} A \Delta_t. \end{aligned}$$

Шаг 3. Значения функционалов в точке $\boldsymbol{\theta}^{t+1}$. По Предположению 4:

$$\begin{aligned} \mathcal{L}_{t+1}(\boldsymbol{\theta}^{t+1}) &= \varepsilon_{t+1}^* + \frac{1}{2} (\boldsymbol{\theta}^{t+1} - \boldsymbol{\theta}_{t+1}^*)^\top A (\boldsymbol{\theta}^{t+1} - \boldsymbol{\theta}_{t+1}^*) \\ &= \varepsilon_{t+1}^* + \frac{t^2}{2} \Delta_t^\top S K^{-1} A K^{-1} S \Delta_t, \\ R_t(\boldsymbol{\theta}^{t+1}) &= \frac{1}{2} (\boldsymbol{\theta}^{t+1} - \boldsymbol{\theta}^t)^\top S (\boldsymbol{\theta}^{t+1} - \boldsymbol{\theta}^t) = \frac{1}{2} \Delta_t^\top A K^{-1} S K^{-1} A \Delta_t. \end{aligned}$$

Подставляя в (27):

$$\begin{aligned} \mathcal{L}_t^*(u_t) &= \frac{1}{t+1} \left[\varepsilon_{t+1}^* + \frac{t^2}{2} \Delta_t^\top S K^{-1} A K^{-1} S \Delta_t \right] + \frac{t}{t+1} \cdot \frac{1}{2} \Delta_t^\top A K^{-1} S K^{-1} A \Delta_t \\ &= \frac{\varepsilon_{t+1}^*}{t+1} + \frac{t}{2(t+1)} \Delta_t^\top [t S K^{-1} A K^{-1} S + A K^{-1} S K^{-1} A] \Delta_t. \end{aligned} \quad (32)$$

Шаг 4. Алгебраическое тождество. Из определения $K = A + tS$ умножением на K^{-1} справа и слева получаем

$$A K^{-1} + t S K^{-1} = I, \quad K^{-1} A + t K^{-1} S = I,$$

откуда $S K^{-1} = \frac{1}{t} (I - A K^{-1})$ и $K^{-1} S = \frac{1}{t} (I - K^{-1} A)$. Матрицы A , S симметричны, поэтому $K = K^\top$ и $K^{-1} = (K^{-1})^\top$. Прямое умножение дает $S K^{-1} A =$

$\frac{1}{t}(A - AK^{-1}A)$, а $AK^{-1}S = (SK^{-1}A)^\top$ совпадает с правой частью по симметрии. Тожество не требует общей собственной базы для A и S . Отсюда

$$AK^{-1}S = SK^{-1}A = \frac{1}{t}(A - AK^{-1}A). \quad (33)$$

По этим тождествам левая часть (32) переписывается покомпонентно:

$$\begin{aligned} tSK^{-1}AK^{-1}S &= (I - AK^{-1})AK^{-1}S = AK^{-1}S - \frac{1}{t}(AK^{-1}A - AK^{-1}AK^{-1}A), \\ AK^{-1}SK^{-1}A &= AK^{-1} \cdot SK^{-1}A = \frac{1}{t}(AK^{-1}A - AK^{-1}AK^{-1}A). \end{aligned}$$

При суммировании члены $\frac{1}{t}(AK^{-1}A - AK^{-1}AK^{-1}A)$ взаимно сокращаются:

$$tSK^{-1}AK^{-1}S + AK^{-1}SK^{-1}A = AK^{-1}S = H_{t+1}(H_{t+1} + t\Sigma_t)^{-1}\Sigma_t.$$

Шаг 5. Финальная формула. Подставляя в (32):

$$\mathcal{L}_t^*(u_t) = \frac{\varepsilon_{t+1}^*}{t+1} + \frac{t}{2(t+1)} \Delta_t^\top H_{t+1}(H_{t+1} + t\Sigma_t)^{-1}\Sigma_t \Delta_t = \frac{\varepsilon_{t+1}^*}{t+1} + \pi_t.$$

□

Г.3. Доказательство Теоремы 4

При расписании $u_t = 1/(t+1)$ веса из Определения 2 принимают вид $w_{s,T} = 1/T$ для всех s . Проверка: $w_{1,T} = \prod_{r=1}^{T-1} r/(r+1) = 1/T$ телескопически, а при $s \geq 2$ имеем $w_{s,T} = \frac{1}{s} \prod_{r=s}^{T-1} r/(r+1) = \frac{1}{s} \cdot \frac{s}{T} = 1/T$. Поэтому $\mathcal{L}_T^{(w)} = \mathcal{L}_T = \frac{1}{T} \sum_{s=1}^T \mathcal{L}_s(\theta^T)$.

При идеальном генераторе $\bar{\mathcal{E}}_t = 0$. В доказательстве Теоремы 3 рекурсия Шага 3 до релаксации $\mathcal{L}_t^*(u_t) \leq \varepsilon_t$ имеет вид $\mathcal{L}_{t+1}^{(w)} \leq \mathcal{L}_t^*(u_t) + (1 - u_t)\mathcal{L}_t^{(w)}$. При точной внутренней оптимизации подстановка значений $\mathcal{L}_j^*(u_j)$ из Леммы 5 ниже дает более тугую оценку, чем формулировка Теоремы 3 через ε_j . Разворачивая рекурсию с $\mathcal{L}_0^{(w)} = 0$, получаем

$$\mathcal{L}_T \leq \sum_{j=0}^{T-1} \left(\prod_{r=j+1}^{T-1} (1 - u_r) \right) \mathcal{L}_j^*(u_j). \quad (34)$$

Шаг 1. Произведения $(1 - u_r)$ телескопируют. При $1 - u_r = r/(r + 1)$

$$\prod_{r=j+1}^{T-1} \frac{r}{r+1} = \frac{(j+1)(j+2)\cdots(T-1)}{(j+2)(j+3)\cdots T} = \frac{j+1}{T}.$$

Шаг 2. Подстановка из Леммы 5. Имеем $\mathcal{L}_j^*(u_j) = \varepsilon_{j+1}^*/(j+1) + \pi_j$. Тогда

$$\mathcal{L}_T \leq \sum_{j=0}^{T-1} \frac{j+1}{T} \left[\frac{\varepsilon_{j+1}^*}{j+1} + \pi_j \right] = \frac{1}{T} \sum_{j=0}^{T-1} \varepsilon_{j+1}^* + \frac{1}{T} \sum_{j=0}^{T-1} (j+1)\pi_j = \bar{\varepsilon}^* + \frac{1}{T} \sum_{t=0}^{T-1} (t+1)\pi_t,$$

где $\bar{\varepsilon}^* = \frac{1}{T} \sum_{s=1}^T \varepsilon_s^*$, что совпадает с (19). $\square$

Г.4. Доказательство Следствия 1

По Шагу 5 доказательства Леммы 5

$$\pi_t = \frac{t}{2(t+1)} \Delta_t^\top H_{t+1} (H_{t+1} + t\Sigma_t)^{-1} \Sigma_t \Delta_t.$$

Положим $K = H_{t+1} + t\Sigma_t$ и покажем, что условие $H_{t+1}\Sigma_t = 0$ влечет $H_{t+1}K^{-1}\Sigma_t = 0$. Для произвольного u обозначим $v = K^{-1}\Sigma_t u$. Тогда $Kv = \Sigma_t u$, откуда $H_{t+1}v = \Sigma_t u - t\Sigma_t v = \Sigma_t(u - tv)$. По условию $H_{t+1}\Sigma_t = 0$, поэтому $H_{t+1}^2 v = H_{t+1}\Sigma_t(u - tv) = 0$. Для симметричной положительно полуопределенной матрицы равенство $H_{t+1}^2 v = 0$ равносильно $H_{t+1}v = 0$, откуда $H_{t+1}K^{-1}\Sigma_t u = 0$. Поскольку u произвольно, $H_{t+1}K^{-1}\Sigma_t = 0$ и $\pi_t = 0$ для всех t .

При $\pi_t = 0$ для всех t из (19) получаем $\mathcal{L}_T \leq \bar{\varepsilon}^*$. С другой стороны, $\mathcal{L}_s(\theta) \geq \varepsilon_s^*$ для любых весов θ по Предположению 4, поэтому

$$\mathcal{L}_T = \frac{1}{T} \sum_{s=1}^T \mathcal{L}_s(\theta^T) \geq \frac{1}{T} \sum_{s=1}^T \varepsilon_s^* = \bar{\varepsilon}^*.$$

Два встречных неравенства дают равенство $\mathcal{L}_T = \bar{\varepsilon}^*$. $\square$

Г.5. Доказательство Теоремы 5

При $t = 0$ множитель $t/(2(t+1))$ в определении π_t обращает $\pi_0 = 0$ независимо от структуры H_1 и Σ_0 , и оценка $\pi_0 \leq LD^2/(2(0+1))$ выполнена тривиально. Пусть далее $t \geq 1$. Положим $K = H_{t+1} + t\Sigma_t$. По Шагу 5 доказательства Леммы 5

и тождеству (33) имеем

$$H_{t+1}K^{-1}\Sigma_t = \frac{1}{t}(H_{t+1} - H_{t+1}K^{-1}H_{t+1}),$$

откуда

$$\pi_t = \frac{1}{2(t+1)} \left(\Delta_t^\top H_{t+1} \Delta_t - \Delta_t^\top H_{t+1} K^{-1} H_{t+1} \Delta_t \right).$$

Второе слагаемое неотрицательно: при $w = H_{t+1} \Delta_t$ имеем $\Delta_t^\top H_{t+1} K^{-1} H_{t+1} \Delta_t = w^\top K^{-1} w \geq 0$, так как $K \succ 0$. Поэтому

$$\pi_t \leq \frac{1}{2(t+1)} \Delta_t^\top H_{t+1} \Delta_t \leq \frac{\|H_{t+1}\|_{\text{op}} \|\Delta_t\|^2}{2(t+1)} \leq \frac{LD^2}{2(t+1)}.$$

Подставляя в (19), получаем

$$\mathcal{L}_T - \bar{\varepsilon}^* \leq \frac{1}{T} \sum_{t=0}^{T-1} (t+1) \cdot \frac{LD^2}{2(t+1)} = \frac{1}{T} \cdot T \cdot \frac{LD^2}{2} = \frac{LD^2}{2}.$$

□

Приложение Д. Bias-variance анализ и связь с классической теорией

В этом приложении приведены полные доказательства результатов из подраздела 3.2 о редукции шага Generative Replay к экспоненциальному скользящему среднему, разложении средней ошибки на смещение и дисперсию и условиях сходимости в среднем квадратичном.

Д.1. Доказательство Леммы 6

По Предположению 5 все задачи имеют одинаковый гессиан $H_s = H$, а операционный гессиан функционала повторения $\Sigma_t = H$. Подставляя в (17):

$$M_t = u_t H + (1 - u_t) H = H.$$

Матрица M_t совпадает с H и невырождена при положительно определенном H , поэтому $M_t^{-1} = H^{-1}$ и $M_t^{-1} H = I$. Подставляя в выражение для шага:

$$\boldsymbol{\theta}^{t+1} = H^{-1} [u_t H \boldsymbol{\theta}_{t+1}^* + (1 - u_t) H \boldsymbol{\theta}^t] = u_t \boldsymbol{\theta}_{t+1}^* + (1 - u_t) \boldsymbol{\theta}^t = (1 - u_t) \boldsymbol{\theta}^t + u_t \boldsymbol{\theta}_{t+1}^*.$$

Шаг GR принимает вид экспоненциального скользящего среднего по последовательности оптимумов задач. $\square$

Д.2. Доказательство Теоремы 6

По Лемме 6 при Предположениях 5 и 6 шаг GR имеет вид экспоненциального скользящего среднего $\boldsymbol{\theta}^{t+1} = (1 - u_t) \boldsymbol{\theta}^t + u_t \boldsymbol{\theta}_{t+1}^*$. Раскрывая рекурсию с начальным $\boldsymbol{\theta}^0$,

$$\boldsymbol{\theta}^t = \Pi_t \boldsymbol{\theta}^0 + \sum_{s=0}^{t-1} w_s^{(t)} \boldsymbol{\theta}_{s+1}^*, \quad \Pi_t = \prod_{s=0}^{t-1} (1 - u_s), \quad w_s^{(t)} = u_s \prod_{k=s+1}^{t-1} (1 - u_k). \quad (35)$$

Шаг 1. Нормировка весов. Покажем, что $\Pi_t + \sum_{s=0}^{t-1} w_s^{(t)} = 1$. База: $\Pi_1 + w_0^{(1)} = (1 - u_0) + u_0 = 1$. Переход: при справедливости равенства для t

$$\Pi_{t+1} + \sum_{s=0}^t w_s^{(t+1)} = (1 - u_t) \Pi_t + (1 - u_t) \sum_{s=0}^{t-1} w_s^{(t)} + u_t = (1 - u_t) \cdot 1 + u_t = 1.$$

В частности, $\sum_{s=0}^{t-1} w_s^{(t)} = 1 - \Pi_t$.

Шаг 2. Математическое ожидание. По линейности и условию $\mathbb{E}[\boldsymbol{\theta}_{s+1}^*] = \mu^*$ имеем

$$\mathbb{E}[\boldsymbol{\theta}^t] = \Pi_t \boldsymbol{\theta}^0 + \mu^*(1 - \Pi_t) = \mu^* + \Pi_t(\boldsymbol{\theta}^0 - \mu^*).$$

Отсюда $\mathbb{E}[\boldsymbol{\theta}^t] - \mu^* = \Pi_t(\boldsymbol{\theta}^0 - \mu^*)$, что есть первое утверждение теоремы.

Шаг 3. Ковариация. Центрированная величина имеет вид

$$\boldsymbol{\theta}^t - \mathbb{E}[\boldsymbol{\theta}^t] = \sum_{s=0}^{t-1} w_s^{(t)} (\boldsymbol{\theta}_{s+1}^* - \mu^*).$$

Слагаемые независимы, каждое имеет ковариационную матрицу C^* . Дисперсия суммы независимых случайных векторов равна сумме дисперсий, откуда

$$\text{Cov}(\boldsymbol{\theta}^t) = \sum_{s=0}^{t-1} (w_s^{(t)})^2 \text{Cov}(\boldsymbol{\theta}_{s+1}^*) = \left(\sum_{s=0}^{t-1} (w_s^{(t)})^2 \right) C^*.$$

Шаг 4. Среднеквадратичная ошибка. Стандартное разложение MSE на смещение и дисперсию дает

$$\mathbb{E}\|\boldsymbol{\theta}^t - \mu^*\|^2 = \|\mathbb{E}[\boldsymbol{\theta}^t] - \mu^*\|^2 + \text{tr}(\text{Cov}(\boldsymbol{\theta}^t)) = \Pi_t^2 \|\boldsymbol{\theta}^0 - \mu^*\|^2 + \text{tr}(C^*) \sum_{s=0}^{t-1} (w_s^{(t)})^2,$$

что совпадает с (24). □

Д.3. Доказательство Теоремы 7

Считаем $u_s \in [0, 1)$ (значение $u_s = 1$ обращает Π_t в нуль за один шаг и не интересно).

Часть 1. Эквивалентность $\Pi_t \rightarrow 0 \Leftrightarrow \sum u_t = \infty$. *Достаточность.* При $x \in [0, 1)$ верно $\log(1 - x) \leq -x$, поэтому

$$\log \Pi_t = \sum_{s=0}^{t-1} \log(1 - u_s) \leq - \sum_{s=0}^{t-1} u_s.$$

Если $\sum u_s = \infty$, правая часть уходит в $-\infty$, и $\Pi_t \rightarrow 0$.

Необходимость. Покажем обратную импликацию через ее контрапозицию: при $\sum u_s < \infty$ величина Π_t не стремится к нулю. Имеем $u_s \rightarrow 0$, и найдется N , на котором $u_s \leq 1/2$ при $s \geq N$. На промежутке $x \in [0, 1/2]$ выполнено $\log(1-x) \geq -2x$ (производная $\log(1-x) + 2x$ по x равна $(1-2x)/(1-x) \geq 0$, а в нуле значение нулевое). Тогда

$$\log \Pi_t \geq \log \Pi_N - 2 \sum_{s=N}^{t-1} u_s \geq \log \Pi_N - 2 \sum_{s=0}^{\infty} u_s.$$

Правая часть конечна и от t не зависит, значит Π_t ограничен снизу положительной постоянной.

Часть 2. При $\sum u_t = \infty$ и $u_t \rightarrow 0$ имеем $\sum_s (w_s^{(t)})^2 \rightarrow 0$. Зафиксируем $\varepsilon > 0$. По $u_s \rightarrow 0$ найдется N , при котором $u_s \leq \varepsilon$ для $s \geq N$. Разобьем сумму на голову и хвост:

$$\sum_{s=0}^{t-1} (w_s^{(t)})^2 = \sum_{s=0}^{N-1} (w_s^{(t)})^2 + \sum_{s=N}^{t-1} (w_s^{(t)})^2. \quad (36)$$

Оценка хвоста. По определению $w_s^{(t)} = u_s \prod_{k>s} (1-u_k) \leq u_s$, поэтому $w_s^{(t)} \leq \varepsilon$ при $s \geq N$. Сумма квадратов оценивается через сумму первых степеней:

$$\sum_{s=N}^{t-1} (w_s^{(t)})^2 \leq \varepsilon \sum_{s=N}^{t-1} w_s^{(t)} \leq \varepsilon \sum_{s=0}^{t-1} w_s^{(t)} = \varepsilon(1 - \Pi_t) \leq \varepsilon.$$

Оценка головы. Для $s < N$ и $t > N$

$$w_s^{(t)} = u_s \left(\prod_{k=s+1}^{N-1} (1-u_k) \right) \left(\prod_{k=N}^{t-1} (1-u_k) \right) \leq u_s \prod_{k=N}^{t-1} (1-u_k).$$

По части 1 теоремы $\sum_{k \geq N} u_k = \infty$ влечет $\prod_{k=N}^{t-1} (1-u_k) \rightarrow 0$ при $t \rightarrow \infty$. Поэтому $w_s^{(t)} \rightarrow 0$ для каждого фиксированного $s < N$, а сумма $\sum_{s < N} (w_s^{(t)})^2$ из конечного числа слагаемых тоже стремится к нулю.

Из (36) получаем $\limsup_t \sum_s (w_s^{(t)})^2 \leq \varepsilon$. Произвольность ε дает требуемую сходимость к нулю.

Часть 3. Итог. По Теореме 6

$$\mathbb{E}\|\boldsymbol{\theta}^t - \mu^*\|^2 = \Pi_t^2 \|\boldsymbol{\theta}^0 - \mu^*\|^2 + \text{tr}(C^*) \sum_{s=0}^{t-1} (w_s^{(t)})^2.$$

Первое слагаемое стремится к нулю по части 1, второе слагаемое стремится к нулю по части 2. Сумма стремится к нулю. $\square$

Приложение Е. Детали экспериментов

В этом приложении приведены полные конфигурации всех экспериментов из Раздела 4: использованные значения гиперпараметров, размеры выборок, число итераций оптимизации и число независимых запусков. Исходный код экспериментов, скрипты запуска и конфигурации сохранены в репозитории

https://gitlab.com/repeated_ml/dynamic-replay

Е.1. Деградация системы при прогнозировании цен

Эксперимент из подраздела 4.1. Гиперпараметры приведены в Таблице 1.

Таблица 1: Гиперпараметры эксперимента по деградации системы при прогнозировании цен.

Параметр	Значение
Датасет	California Housing [38]
Начальный размер активной выборки N_0	20 640
Число признаков	8
Модель регрессии цен	градиентный бустинг (scikit-learn [43])
Период переобучения τ	30 шагов
Горизонт эксперимента	30 000 шагов
Сравниваемые стратегии управления	нулевая, наивная жадная, аккуратная жадная
Уровень риска δ в условии (11)	0,1
Число независимых запусков	5

Е.2. Регрессия параболы линейной моделью

Эксперимент из подраздела 4.2.2. Гиперпараметры приведены в Таблице 2.

Таблица 2: Гиперпараметры эксперимента с регрессией параболы.

Параметр	Значение
Целевая функция	$y = x^2$ на $T = 10$ участках $x \sim \text{Uniform}[s, s + 1]$
Модель	линейная регрессия $\hat{y} = w_0 + w_1 x$
Длина буфера W	500
Оптимизатор	стохастический градиентный спуск
Шаг обучения η	10^{-2}
Число итераций на блок N	500
Сравниваемые расписания	inv с $u_t = \alpha/(t + 1)$ const с $u_t = u$ exp с $u_t = (e^{-\alpha t/(T-1)} - e^{-\alpha})/(1 - e^{-\alpha})$
Число независимых реализаций	5

Е.3. Ортогональные носители гессианов

Эксперимент из подраздела 4.2.3. Гиперпараметры приведены в Таблице 3.

Таблица 3: Гиперпараметры эксперимента с ортогональными носителями гессианов.

Параметр	Значение
Число задач T	10
Структура задач	$X_s = \sigma_s z_s v_s^\top$, $Y_s = \sigma_s z_s$, v_s из ортонормированной V
Длина буфера W	300
Оптимизатор	стохастический градиентный спуск
Шаг обучения η	10^{-2}
Число итераций на блок N	300
Сравниваемые расписания	$\text{inv с } u_t = \alpha/(t+1)$ $\text{const с } u_t = u$ $\text{exp с } u_t = (e^{-\alpha t/(T-1)} - e^{-\alpha})/(1 - e^{-\alpha})$
Число независимых реализаций	5

Е.4. Жадный выбор порядка задач

Эксперимент из подраздела 4.2.4. Гиперпараметры приведены в Таблице 4.

Таблица 4: Гиперпараметры эксперимента по жадному выбору порядка задач.

Параметр	Значение
Размерность параметра d	50
Число задач T	$\{3, 4, 5, 6, 7\}$
Гессианы H_s	$U_s \Lambda_s U_s^\top$, $U_s \in O(d)$ случайная ортогональная
Собственные значения	$\lambda_{s,i} \sim \text{LogUnif}[1, 10]$
Оптимумы фоновых задач	$\theta_s^* \sim 0,1 \cdot \mathcal{N}(0, I_d)$, $s \neq s^*$
Оптимум выделенной задачи	$\theta_{s^*}^* = R/\sqrt{d} \cdot \xi$, $\xi \sim \mathcal{N}(0, I_d)$, $R = 20$
Функция потерь	$\mathcal{L}_s(\theta) = \frac{1}{2} \ \theta - \theta_s^*\ _{H_s}^2$
Внутренний шаг	один шаг градиентного спуска с $\eta_t = 0,5/\lambda_{\max}(M_t)$
Стратегии порядка	жадная, антижадная, случайная, оптимальная (полный перебор)
Число выборок для случайного порядка	200
Число независимых реализаций на T	30

Е.5. Bias-variance разложение

Эксперимент из подраздела 4.2.5. Гиперпараметры приведены в Таблице 5.

Таблица 5: Гиперпараметры эксперимента по bias-variance разложению.

Параметр	Значение
Размерность параметра d	20
Гессианы задач H_s и Σ_t	I_d
Оптимумы задач θ_s^*	$\mathcal{N}(0, I_d)$
Истинный центр μ^*	0
След ковариации $\text{tr}(C^*)$	20
Начальное состояние θ^0	$(1, \dots, 1)$
Число блоков T	10^5
Сравниваемые расписания	inv с $u_t = 1/(t+1)$ const с $u \in \{0,1; 0,2; 0,3; 0,5; 0,7; 0,8; 0,9\}$ quad с $u_t = 1/(t+1)^2$
Число независимых реализаций K	3000

E.6. ChestX-Ray

Эксперимент из подраздела 4.2.6. Гиперпараметры обучения приведены в Таблице 6, сравниваемые расписания управления в Таблице 7. Для гиперпараметров η , размера минибатча и числа эпох на блок перечислены все значения, которые перебирались в ходе подбора. **Жирным** выделены финальные значения, использованные в основном сводном сравнении (Рис. 9–10).

Таблица 6: Гиперпараметры обучения для эксперимента на NIH ChestX-Ray.

Параметр	Значение
Датасет	NIH ChestX-Ray [36]
Болезни	Atelectasis, Cardiomegaly, Consolidation, Edema, Effusion
Начальное состояние	класс «норма»
Размер обучающей выборки на задачу N	4000
Длина буфера W	4000
Модель	MobileNetV2 [37], предобученная на ImageNet
Размер входного изображения	224×224
Оптимизатор	Adam [45]
Шаг обучения η	$\{10^{-4}; 2 \cdot 10^{-4}; 2,5 \cdot 10^{-4}; \mathbf{3 \cdot 10^{-4}}; 4 \cdot 10^{-4}; 5 \cdot 10^{-4}; 10^{-3}\}$
Размер минибатча	$\{48; \mathbf{64}; 96\}$
Число эпох на блок	$\{3; 5; 15; 20; \mathbf{25}; 30; 35; 40; 45; 50\}$
Метрика	AUC, сводные Avg6 и Avg5
Число независимых запусков	5

Таблица 7: Сравниваемые стратегии на NIH ChestX-Ray.

Стратегия	Значения параметров
multiclass	совместное обучение, верхний ориентир
inv с α	$\{1,0; 1,5\}$
const с u	$\{0,10; 0,20; 0,30; 0,40; 0,55; 0,62; 0,65; 0,80\}$
exp	$u_1 \in \{0,65; 0,70\}$ и $u_1 = 0,65, \alpha = 2,2$
adaptive с λ	$\{0,5; 1,0; 1,5\}, u_{\min} = 0,05, u_{\max} = 0,95$