

Оптимальное управление в системах машинного обучения с обратной связью: предотвращение деградации и оттока пользователей

А.С. Веприков¹, А.С. Хританков¹

¹Московский физико-технический институт (национальный исследовательский университет)

В исследовании рассматривается оптимальное управление в системе машинного обучения (МО) с скрытой петлей обратной связи. Ранее изучалось влияние внешней среды на формирование обучающего набора данных и прогнозов модели МО [1, 2] в условиях непрерывного (life-long) обучения. Настоящая работа вводит механизм управления, воздействующий на предсказания алгоритма искусственного интеллекта (ИИ) и, вследствие обратной связи, на поступающие данные. В качестве примера анализируется прогнозирование цен на недвижимость: если пользователи следуют рекомендациям модели МО, её предсказания начинают формировать обучающую выборку, создавая замкнутый цикл, который может управлять уровнем цен.

В данной работе также рассматривается эффект *деградации системы*, при котором некачественные рекомендации алгоритма МО приводят к постепенному оттоку пользователей, что может оставаться незаметным при анализе стандартных метрик. Рассмотрим пример с недвижимостью. Если пользователи следуют рекомендациям ИИ, а алгоритм управления постоянно повышает цены, метрики качества будут оставаться высокими. Однако со временем стоимость жилья станет недоступной для большинства пользователей, что снизит число сделок и приведет к постепенному отказу от использования платформы. Таким образом, несмотря на рост локальных метрик, система в долгосрочной перспективе может деградировать.

Для демонстрации данного эффекта в работе проводится вычислительный эксперимент. На каждом шаге t в системе представлен активный датасет размером N_t , содержащий признаки объектов недвижимости X_t и их цены y_t . Процесс обновления данных происходит следующим образом: случайно выбирается индекс $i \sim U(1, N_0)$, вычисляется предсказание модели: $z = m_t(X_0[i]) + u_t$, где m_t – модель МО дообучаемая каждые T шагов и u_t – управление. Целевая переменная $y_0[i]$ заменяется на z , и элемент $(X_0[i], z)$ добавляется в активный датасет с вероятностью $p \propto \exp[-(z - y_0[i])]$, а с вероятностью $1 - p$ элемент i удаляется из (X_t, y_t) . Данный механизм моделирует поведение пользователей: с вероятностью p они следуют предсказаниям модели, но при высокой цене вероятность покупки снижается. Целью управления является повысить цены как можно больше.

Задача оптимального управления в системе многократного обучения с обратной связью может быть формализована в терминах частично наблюдаемого марковского процесса принятия решений (PoMDP) [3] с дополнительными уточнениями. Введем необходимые обозначения: пусть f – множество всех функций плотности данных системы для обучения модели МО, h – плотность распределения весов модели МО; u – допустимое управление; P – оператор эволюции плотностей состояний системы f (решения пользователей) и H – оператор эволюции плотности весов модели МО h (алгоритм обучения); F – желаемое (целевое) множество функций распределения данных системы f , в которое нужно попасть при помощи управлений u ; $\gamma \in (0; 1)$ – дисконтирующий коэффициент; $g(f, h)$ – функция, показывающая, что при весах модели $\sim h$ на данных $\sim f$ сохранится петля обратной связи. Используя эти обозначения можно определить оптимизационную задачу:

$$\min_{u_0, \dots, u_\infty} \sum_{t=0}^{\infty} \gamma^t \rho(f_t, F), \text{ s.t.: } h_{t+1} = H_t(f_t, h_t, u_t), f_{t+1} = P_t(f_t, h_{t+1}), g(f_t, h_{t+1}) \leq 0. \quad (1)$$




Рис. 1. Результаты эксперимента с моделированием деградации системы

Одним из классических подходов к решению данной оптимизационной задачи является жадный алгоритм. Поскольку в системе присутствует петля обратной связи, управление выходами модели МО влияет на распределение данных в последующем. Жадный алгоритм на каждом шаге t выбирает управление, минимизирующее расстояние $\rho(f_{t+1}, F)$, подбирая выходы модели, наиболее близкие к целевому множеству F . Однако этот метод не учитывает возможную деградацию системы. Даже при значительном оттоке пользователей обратная связь может сохраняться на локальном уровне, искажая оценку качества модели и приводя к нежелательным долгосрочным последствиям.

Результаты эксперимента на рис. 1 показывают, что при обычном жадном управлении наблюдается процесс деградации системы, хотя метрики качества обученной модели МО растут. Для решения этой проблемы нужно вводить более “аккуратное” управление. Проблему можно решить, модифицировав функцию g из постановки задачи (1), введя в нее зависимость от $\hat{f}_t$ – оценки плотности данных на шаге t . Если отличие между $\hat{f}_t$ и f_t незначительно, система остается стабильной, и возможно применение жадного управления. В противном случае требуется корректировка стратегии, чтобы избежать деградации. В эксперименте это отличие можно аппроксимировать через количество остающихся элементов в выборке N_t , где “выживаемость” пользователей из исходного набора может быть представлена как зависимость от размера выборки. Чем больше N_t , тем меньше влияет управление в одной сделке на всех остающихся пользователей. Как показано на рис. 1, такой подход позволяет избежать деградации системы, при этом приближая распределение данных к целевому.

В данной работе исследована проблема деградации систем машинного обучения с наличием скрытой петли обратной связи. Показано, что жадные алгоритмы управления, несмотря на высокие значения метрик качества, могут приводить к постепенному оттоку пользователей и коллапсу системы. Для решения этой проблемы предложена модифицированная стратегия управления, учитывающая изменения в распределении данных путем введения дополнительной зависимости в функцию обратной связи. Эксперименты показали, что данный подход снижает риск деградации и позволяет поддерживать стабильность системы в долгосрочной перспективе.

Литература

1. Веприков А. С., Афанасьев А. П., Хританков А.С. Математическая модель эффекта обратной связи в системах искусственного интеллекта // Математические методы распознавания образов. 2023. С. 35-37
2. Khritankov A. Positive feedback loops lead to concept drift in machine learning systems // Applied Intelligence. 2023. V. 53(19). P. 22648-22666.
3. Kurniawati H. Partially observable markov decision processes and robotics // Annual Review of Control, Robotics, and Autonomous Systems. 2022. V. 5(1). P. 253-277.