

# Задача оптимального управления в системах искусственного интеллекта с обратной связью

Андрей Сергеевич Веприков  
Научный руководитель: к. ф.-м. н. А. С. Хританков

Кафедра интеллектуальных систем ФПМИ МФТИ  
Специализация: Интеллектуальный анализ данных

Москва, 2026

## Положения, выносимые на защиту

1. Единая постановка задачи оптимального управления для систем машинного обучения со скрытой петлей обратной связи.
2. Эффект деградации системы при прогнозировании цен как частный случай постановки. Предложено условие на сохранение наблюдаемой выборки.
3. Метод Generative Replay сведен к этой постановке через управление  $u_t \in [0, 1]$  и условие  $\varepsilon_t$ -допустимости.
4. Верхняя оценка средней ошибки модели для произвольного расписания. Спектральная оценка финальной ошибки через гессианы задач без предположения об их коммутативности.
5. Оценка финальной ошибки через  $\sum_t \|\Delta_t\|^2$ , обосновывающая жадный выбор порядка задач. Условия сходимости в среднем квадратичном, совпадающие с условиями Роббинса-Монро.
6. Экспериментальная проверка на синтетических задачах и на реальном датасете медицинских изображений NIH ChestX-Ray.

# Постановка задачи

Система МО с петлей обратной связи: предсказания модели на шаге  $t$  через реакцию среды меняют обучающую выборку на шаге  $t + 1$ .

Состояние системы — пара  $(f_t, h_t)$ :  $f_t$  есть плотность данных среды,  $h_t$  есть плотность весов модели  $\theta^t$ .

$$h_{t+1} = \mathbf{H}_t(f_t, h_t, u_t), \quad f_{t+1} = \mathbf{P}_t(f_t, h_{t+1}).$$

$\mathbf{H}_t$  — оператор обучения,  $\mathbf{P}_t$  — оператор реакции среды.

Управление  $u_t$  действует только на алгоритм обучения.

## Оптимизационная задача

$$\max_{u_1, \dots, u_T} \sum_{t=0}^T \gamma^t r(f_t, h_{t+1}) \quad \text{при условии} \quad g(f_t, h_{t+1}) \leq 0.$$

Условие  $g \leq 0$  задает требования к сохранению петли обратной связи и к невырождению системы.

## Пример 1. Деградация системы. Постановка


Модель регрессии  $m_{\theta^t}$  предсказывает цены на жилье. На шаге  $t$  случайному покупателю предлагается цена

$$z_t = m_{\theta^t}(\mathbf{x}_i) + u_t.$$

С вероятностью

$$p_t \propto \exp[-(z_t - y_i^0)/y_i^0]$$


покупатель соглашается, и пара  $(\mathbf{x}_i, z_t)$  заменяет элемент активной выборки. Иначе индекс  $i$  удаляется. Цель управления: максимизировать среднюю цену сделки, не разрушив петлю.



## Пример 1. Деградация системы. Результаты

Два варианта условия  $g$  задают две жадные стратегии:

- ▶ **Наивная.**  $g(f_t, h_{t+1}, u_t) = -\log p_t$ . Максимизируем вероятность сделки на текущем покупателе.
- ▶ **Аккуратная.**  $g(f_t, h_{t+1}, u_t) = \delta - N_{t+1}/N_t$ . Максимизируем долю сохраненной выборки.



Наивная стратегия максимизирует локальную метрику  $R^2$  и одновременно ведет  $N_t \rightarrow 0$ , то есть формально метрика растет, а система деградирует. Аккуратная стратегия сохраняет  $N_t$  на стабильном уровне,  $R^2$  растет медленнее, но система продолжает работать.

## Пример 2. Generative Replay как задача управления


Поток задач  $D_1, \dots, D_T$ . Управление  $u_t \in [0, 1]$  — доля новых данных в обучающей выборке. Часть  $(1 - u_t)$  синтезируется генератором  $G_t$  с метками самодистилляции от  $m_{\theta^t}$ .

Функционал обучения:

$$\mathcal{L}_{\text{train}}(\theta, u_t) = u_t \mathbb{E}_{(\mathbf{x}, y) \sim D_{t+1}} [\mathcal{L}(m_{\theta}(\mathbf{x}), y)] \\ + (1 - u_t) \mathbb{E}_{\mathbf{x}' \sim G_t} [\mathcal{L}(m_{\theta}(\mathbf{x}'), m_{\theta^t}(\mathbf{x}'))].$$

Условие  $g$  принимает форму  $\varepsilon_t$ -допустимости:

$$\mathcal{L}_t^*(u_t) = \min_{\theta} \mathcal{L}_{\text{train}}(\theta, u_t) \leq \varepsilon_t.$$



# Теорема 1. Верхняя оценка средней ошибки

## Теорема 1 (Верхняя оценка средней ошибки)

Рассмотрим взвешенную среднюю ошибку


$$\mathcal{L}_T^{(w)} = \sum_{s=1}^T w_{s,T} \cdot \mathcal{L}_s(\theta^T),$$

где веса  $w_{s,T}$  индуцируются расписанием  $u_T$ . Пусть  $\bar{\mathcal{E}}_j$  — накопленная ошибка генератора. Тогда при  $\varepsilon_T$ -допустимости управления

$$\mathcal{L}_T^{(w)} \leq \sum_{s=1}^T \left( \prod_{r=s}^T (1 - u_r) \right) \varepsilon_s + \sum_{s=1}^T \left( \prod_{r=s}^T (1 - u_r) \right) \bar{\mathcal{E}}_s,$$

При  $u_t = \frac{1}{t+1}$  веса равномерны ( $w_{s,T} = 1/T$ ) и оценка принимает вид

$$\mathcal{L}_T \leq \frac{1}{T} \sum_{s=1}^T s \cdot \varepsilon_s + \frac{1}{T} \sum_{s=2}^T s \cdot \bar{\mathcal{E}}_s.$$



# Спектральная теория и условие нулевого конфликта

- ▶  $R_t(\theta) = \mathbb{E}_{\mathbf{x} \sim G_t}[\mathcal{L}(m_\theta(\mathbf{x}), m_{\theta^t}(\mathbf{x}))]$ ,  $\Sigma_t = \nabla^2 R_t(\theta^t)$  — функционал и гессиан повторения на шаге  $t + 1$ .
- ▶  $\theta_{t+1}^*, \varepsilon_{t+1}^* = \mathcal{L}_{t+1}(\theta_{t+1}^*)$ ,  $H_{t+1} = \nabla^2 \mathcal{L}_{t+1}(\theta_{t+1}^*)$  — оптимум, значение в оптимуме и гессиан новой задачи  $t + 1$ .
- ▶  $\Delta_t = \theta_{t+1}^* - \theta^t$  — смещение оптимума новой задачи  $\theta_{t+1}^*$  от текущей модели  $\theta^t$ .


## Лемма 1 (Замкнутая форма $\mathcal{L}_t^*$ )

В квадратичном приближении при  $u_t = 1/(t + 1)$

$$\varepsilon_t = \mathcal{L}_t^*(u_t) = \frac{\varepsilon_{t+1}^*}{t + 1} + \pi_t, \quad \pi_t = \frac{t}{2(t+1)} \Delta_t^\top H_{t+1} (H_{t+1} + t \Sigma_t)^{-1} \Sigma_t \Delta_t.$$

## Следствие 1 (Условие нулевого конфликта)

Если  $H_{t+1} \Sigma_t = 0$  для всех  $t$ , то  $\pi_t = 0$  и  $\mathcal{L}_T = \bar{\varepsilon}^*$ .





## Теорема 2. Оценка через диаметр траектории

Из Леммы 1 и неравенства  $\pi_t \leq \frac{\|H_{t+1}\|_{\text{op}} \|\Delta_t\|^2}{2(t+1)} \leq \frac{L \|\Delta_t\|^2}{2(t+1)}$ :


Теорема 2 (Оценка через  $\sum \|\Delta_t\|^2$ )

Пусть  $\|H_{t+1}\|_{\text{op}}, \|\Sigma_t\|_{\text{op}} \leq L$ . При  $u_t = 1/(t+1)$

$$\mathcal{L}_T \leq \frac{1}{T} \sum_{t=1}^T \varepsilon_t^* + \frac{L}{2T} \sum_{t=1}^{T-1} \|\Delta_t\|^2.$$

Зависимость от перестановки задач локализована в  $\sum_t \|\Delta_t\|^2$ .

Жадная стратегия минимизирует эту сумму.



# Теорема 3. Сходимость в среднем квадратичном


При одинаковых гессианах  $H_S = H$ ,  $\Sigma_t = H$  и независимых оптимумах  $\theta_s^*$  с  $\mathbb{E}[\theta_s^*] = \mu^*$ ,  $\text{Cov}(\theta_s^*) = C^*$  шаг GR становится экспоненциальным скользящим средним

$$\theta^{t+1} = (1 - u_t)\theta^t + u_t\theta_{t+1}^*.$$

## Теорема 3 (Условия сходимости)


Если  $\sum_t u_t = \infty$  и  $u_t \rightarrow 0$ , то  $\mathbb{E}\|\theta^t - \mu^*\|^2 \rightarrow 0$ . Условия совпадают с классическими условиями Роббинса-Монро.

Эксперимент на линейной рекурсии: разложение MSE на смещение и дисперсию совпадает с теорией.




# Реальный датасет: NIH ChestX-Ray


Рентгены грудной клетки, пять патологий как задачи  $D_1, \dots, D_5$  бинарной классификации. Модель MobileNetV2, предобученная на ImageNet.



Сравниваются четыре семейства расписаний  $u_t$ : inv ( $u_t = \alpha/(t+1)$ ), const ( $u_t = u$ ), exp (экспоненциально убывающее) и adaptive ( $u_t = r_t/(r_t + t\lambda g_t)$  по наблюдаемым ошибкам).




# ChestX-Ray: сравнение расписаний



Расписание  $u_t = 1,5/(t + 1)$  устойчиво лучшее: уступает совместному обучению на 5,5% по средней метрике AUC.

## ChestX-Ray: динамика AUC по блокам обучения



После первого появления каждого класса модель удерживает AUC около достигнутого уровня без катастрофических потерь.

- ▶ **Теория.** Введена постановка задачи оптимального управления. Эффект деградации и Generative Replay сведены к этой постановке. Доказаны верхняя оценка средней ошибки, спектральная оценка без коммутативности гессианов, оценка через  $\sum_t \|\Delta_t\|^2$ , разложение MSE и условия сходимости.
- ▶ **Эксперименты.** Реализован протокол со скользящим окном. Проведены эксперименты на задаче прогнозирования цен, на синтетических задачах и на NIH ChestX-Ray.
- ▶ **Новизна.** Generative Replay впервые представлен как задача оптимального управления. Условия сходимости согласованы с теорией Роббинса-Монро.

**Спасибо за внимание!**

Готов ответить на вопросы.